



دانشگاه صنعتی امیرکبیر  
(پلی تکنیک تهران)  
دانشکده مهندسی کامپیوتر

پروژه تحقیقاتی درس شبکه‌های عصبی

عنوان:  
ماشین حالت مایع بهبود یافته

نگارش  
علیرضا خیاطیان

استاد  
دکتر صفابخش

بهمن ۱۴۰۰

## چکیده

ماشین حالت مایع (LSM) یک مدل عصبی با محاسبات زمان واقعی است که جریان ورودی‌های متغیر زمانی را به فضای با ابعاد بالاتر تبدیل می‌کند. ماشین حالت مایع یک مدل محاسبات مخزن<sup>۱</sup> (RC) با الهام از ساختارهای بیولوژیکی مغز است که ریزمدارهای قشر مغز را تقلید می‌کند و از شبکه‌های عصبی اسپایکینگ<sup>۲</sup> (SNN) استفاده می‌کند که می‌تواند مستقیماً روی سخت‌افزارهای نورومورفیک اجرا شود. همچنین، LSM به عنوان یک مدل محاسبات مخزن گزینه‌ای مناسب برای استقرار الگوریتم‌های هوش مصنوعی در پلتفرم‌های سیستم نهفته پایین رده می‌باشد. LSM یک زمینه تحقیقاتی جدید در محاسبات الهام گرفته از بیولوژیک است که بیشترین تلاش تحقیقاتی برای آموزش مدل و همچنین یافتن روش بهینه یادگیری را دارد. در این گزارش به بررسی ابعاد مختلف مفاهیم و استفاده از LSM می‌پردازیم. با پیشنهاد روش‌های پیشرفته اخیر در این زمینه قابلیت پیاده‌سازی و عملکرد LSM‌های ارتقا یافته را مورد ارزیابی قرار می‌دهیم.

## واژه‌های کلیدی:

ماشین حالت مایع، محاسبات مخزن، مخزن هوشمند، محدودیت‌های انرژی، ماشین‌های مبتنی بر ممریستور<sup>۳</sup>

---

<sup>1</sup> Reservoir Computing

<sup>2</sup> Spiking Neural Networks

<sup>3</sup> Memristor

صفحه	فهرست مطالب
۱	فصل اول پیشگفتار.....
۲	۱-۲ مقدمه.....
۳	۲-۲ سازماندهی گزارش.....
۴	فصل دوم معماریهای ماشین حالت مایع.....
۵	۱-۲ مقدمه.....
۵	۲-۲ معماری پیشنهادی Jin برای LSM.....
۶	۳-۲ معماری پیشنهادی Azambuja برای LSM.....
۸	۴-۲ معماری پیشنهادی Avesani برای LSM.....
۹	۵-۲ ارزیابی عملکرد مدل‌های مختلف LSM.....
۱۲	۶-۲ نتایج و بحث.....
۱۵	فصل سوم ماشین حالت مایع موازی شده برای تشخیص اقدام غیرعمدی.....
۱۶	۱-۳ انگیزه و طرح مسئله.....
۱۷	۲-۳ تجزیه و تحلیل ویدئو و تشخیص عمل.....
۱۸	۳-۳ محاسبات مخزن.....
۱۸	۴-۳ نورونهای اسپایکینگ.....
۲۲	۵-۳ تاخیر سیناپسی.....
۲۳	۶-۳ بازخوانی مکانی-زمانی.....
۲۴	۷-۳ آزمایش مدل و نتیجه گیری.....
۲۷	فصل چهارم محدودیتهای انرژی در ماشینهای حالت مایع.....
۲۸	۱-۴ هوش مصنوعی در دستگاه‌های لبه‌ای.....
۲۹	۲-۴ هوش مصنوعی در دستگاه‌های لبه‌ای.....
۳۰	۳-۴ محدودیتهای انرژی.....
۳۱	۴-۴ روشهای ارزیابی.....
۳۲	۵-۴ نتیجه گیری.....
۳۴	فصل پنجم ماشینهای حالت مایع مبتنی بر ممریستور.....
۳۵	۱-۵ سیستم های نورومورفیک.....
۳۶	۲-۵ نویز و تغییرپذیری.....
۳۸	۳-۵ مدل سیستم مقاوم در برابر نویز.....

فصل ششم تولید مخزن هوشمند در ماشین های حالت مایع.....	۴۱
۱-۶ انگیزه و طرح مسئله.....	۴۲
۲-۶ مدل شبکه و آموزش آن.....	۴۲
۳-۶ بهینه سازی تکاملی سیستم های نورومورفیک.....	۴۵
۴-۶ آزمایشات.....	۴۶
۵-۶ نتایج.....	۴۷
منابع و مراجع.....	۵۲

- شکل ۱-۱ ساختار عمومی LSM ..... ۳
- شکل ۱-۲ سیستم تشخیص گفتار مبتنی بر LSM ..... ۶
- شکل ۲-۲ بصری سازی بخش مایع LSM: مربع های قرمز نورون های تحریک کننده را نشان می دهند در حالی که الماس های آبی نورونهای بازدارنده را نشان می دهند. خطوط قرمز پیوسته اتصالات تحریکی و خطوط آبی تیره بازدارنده هستند ..... ۷
- شکل ۳-۲ ساختار کنترل کننده بازو.  $X.Y$  مختصات موضع نهایی هستند. همچنین،  $T1$  و  $T2$  گشتاورهای دستوری هستند و  $e1$  و  $e2$  نیز زوایای کنونی میباشند ..... ۸
- شکل ۴-۲ شبکه محاسباتی مخزن. مخزن یک جریان داده ورودی چند بعدی  $x(t)$  را پردازش می کند که یک سری حالت داخلی  $S(t)$  با ابعاد بالا ایجاد می کند. همزمان رمزگشاه تابع خروجی چند بعدی  $y(t)$  مورد نیاز را بر اساس حالات داخلی تولید شده تولید می کنند ..... ۹
- شکل ۵-۲ عملکرد طبقه بندی LSM در سه معیار اتخاذ شده به عنوان تابعی از پیچیدگی طراحی کاهش مییابد ..... ۱۳
- شکل ۶-۲ عملکرد هزینه تاب خوردگی زمان پویا (DTW) با در نظر گرفتن مسیرها به صورت جداگانه. هرچه هزینه DTW کمتر باشد، نتایج بهتری حاصل میشود ..... ۱۳
- شکل ۱-۳ لایه LIF موازی شده: با استفاده از معادله های ۳-۱۳، یک لایه LIF موازی حاوی  $L$  نورون را می توان به صورت مدولار نشان داد ..... ۲۲
- شکل ۲-۳ به روز رسانی و وضعیت LSM: روال به روز رسانی و وضعیت LSM ذکر شده در الگوریتم ۲ در این نمودار شماتیک به تصویر کشیده شده است.  $I(t)$  نشان دهنده جریان ورودی و  $N(t)$  وضعیت لایه مایع را برای هر مرحله زمانی نشان میدهد ..... ۲۳
- شکل ۳-۳ نتایج مقایسه ای از موازی سازی: نورون های LIF موازی شده ما با چندین مرتبه بزرگی برای یک لایه واحد با افزایش نورون ها (سمت چپ) بهتر از نورون های LIF عمومی عمل می کنند. ما همچنین یک لایه از ۵۰۰ نورون LIF را برای ارزیابی عملکرد در حالت دسته ای با اندازه های مختلف (BS) اجرا می کنیم (سمت راست). ۲۵
- شکل ۴-۳ دقت زمانی و حفظ ویژگی ها در طول زمان عملکرد PLSM را افزایش می دهد (سمت چپ). برای  $T=W=100$ ، آزمایش ها نشان می دهند که  $Cout=64$  نتیجه بهینه را ارائه می کند (راست). ۲۶
- شکل ۱-۴ نمودار مخزن ساخته شده با استخرهای انرژی به تصویر کشیده شده است. کره های تیره رنگ (بنفش) نورون های LIF هستند. فلش های خاکستری اتصالات سیناپسی هستند. بیضی های شفاف روشن تر (سبز) حوضچه های انرژی مشترک بین نورون های محصور شده را نشان می دهند ..... ۳۰
- شکل ۱-۵ نويز ممريستور: (سمت چپ) تفاوت بین وضعیت مورد انتظار و واقعی یک دستگاه ممريستيو (بالا سمت راست) تاثیر نويز خواندن (پایین سمت راست) تاثیر نويز نوشتن ..... ۳۷

شکل ۵-۲ طراحی سیگنال مختلط (LSM: سمت چپ) میله متقاطع و مدارهای جانبی آن (راست) جریان داده بین واحدهای مختلف مورد نیاز برای تحقق کامل LSM.....	۳۸
شکل ۵-۵ نمونه داده‌های ورودی از مجموعه داده‌های رقم گفتاری عربی.....	۳۹
شکل ۵-۳ دو کلاس نمونه از مجموعه داده فرکانس مصنوعی مورد استفاده برای تجزیه و تحلیل پایه.....	۳۹
شکل ۵-۴ نمونه داده‌های ورودی از مجموعه داده TIMIT.....	۳۹
شکل ۶-۱ نمودار محاسبات مخزن. ورودی به مخزن (در این مورد مایع) منتقل می‌شود، سپس پس از مدت زمان از پیش تعیین شده، از مخزن نمونه برداری می‌شود و نمونه به عنوان بردار ویژگی به لایه بازخوانی منتقل می‌شود.....	۴۴
شکل ۶-۲ نقشه‌های حرارتی بالا از یک جستجوی شبکه دو سطحی در مخازن به‌طور تصادفی ایجاد شده بر روی مجموعه داده‌های یونوسفر ایجاد شده‌اند. هر بلوک در نقشه حرارتی نشان‌دهنده بهترین دقت از جمعیت ۱۰۰ نفری است. تعداد نوروهای پنهان و چگالی سیناپسی به ترتیب در محورهای $x$ و $y$ متفاوت است.....	۴۸
شکل ۶-۳ هیستوگرام‌های نشان داده شده در بالا نشان‌دهنده توزیع دقت در بین پیکربندی‌های مورد استفاده در جستجوی شبکه است. در یک جستجوی دقیق در میان یک انتخاب خوب از فرآیندها، ممکن است ارزیابی‌های مایع زیادی مورد نیاز باشد. توزیع دقت به‌طور متوسط در رویکرد ریزدانه بالاتر است، اما مخازن با بالاترین عملکرد هنوز هم بخش کوچکی از توزیع کلی هستند.....	۴۹
شکل ۶-۴ ۵۰۰ شبکه برتر از هر یک از روش‌ها. نمودارها نشان می‌دهد که نتایج EONS به سمت عملکرد بالاتر منحرف شده است. تناسب جزئی بیش از حد را می‌توان از طریق تغییر دستی پارامترها برطرف کرد.....	۵۰
شکل ۶-۵ ۵۰۰ دو شکل بالا نمودارهای هگز-بین آزمایشات EONS انجام شده است. طرح بالا سمت چپ دوره ۰ است، و نمودار بالا سمت راست دوره ۱۱ است. هر طرح شامل تمام ۵۰ شبکه از هر ۱۰۰ اجرا برای مجموع $k5$ است. هر شش ضلعی یک سطل را نشان می‌دهد و تمام نمونه‌هایی که در آن ناحیه قرار می‌گیرند در آن سطل ادغام می‌شوند. گرادیان رنگ تعداد نمونه‌های موجود در یک سطل را نشان می‌دهد. EONS بدون توجه به پیکربندی شروع به دقت مورد انتظار همگرا می‌شود، که نتیجه ذاتاً متفاوت از دو نمودار در پایین است. سمت چپ جستجوی شبکه درشت دانه و سمت راست هر ۵ جستجوی شبکه ریز دانه است.....	۵۱

جدول ۱-۲	پارامترهای پیش فرض مایع.....	۱۱
جدول ۱-۳	حذف ماژولهای مختلف با استفاده از ۷ تنظیمات مختلف برای مجموعه داده .Oops.....	۲۴

## فصل اول

## پیشگفتار



## ۲-۱) مقدمه

ماشین‌های حالت مایع (LSM) یک مدل محاسباتی است که اساساً از شبکه‌های عصبی spiking مکرر و تصادفی و چند نورون خواندنی<sup>۴</sup> تشکیل شده است. شبکه عصبی اسپایکینگ<sup>۵</sup> (SNN) از نورون مصنوعی نسل سوم تشکیل شده است که بیشترین الهام را از بیولوژیکی گرفته است. این نسل از نورون‌ها به نسل‌های قبلی نورون‌های مصنوعی ترجیح داده می‌شوند زیرا نورون‌های spiking در حوزه زمانی عمل می‌کنند و محاسبات آنها بر اساس منبع زمانی است. SNN ها در حال تبدیل شدن به یک عامل غالب برای محاسبات نورومورفیک الهام گرفته از مغز هستند که مغز را با سخت افزار محاسباتی تقلید می‌کنند. انتخاب SNN ها به دلیل کارایی و دقت ذاتی آنها در بسیاری از وظایف شناختی است که شامل تشخیص گفتار و طبقه بندی تصویر در میان کارهای دیگر می‌شود.

مدل LSM با دیدگاه علوم اعصاب محاسباتی توسعه داده شده است. یک اصل اساسی LSM در توانایی آن در انجام محاسبات بلادرنگ با تبدیل جریان ورودی متغیر زمان به یک فضای ابعادی بالاتر نهفته است. LSM دارای سه جزء حیاتی است که عبارتند از:

- I. یک لایه ورودی
- II. یک مخزن یا مایع
- III. مدار بازخوانی بدون حافظه

این مخزن دارای تعداد زیادی از نورون‌های نشستی ادغام و آتش<sup>۶</sup> (LIF) است که به طور بازگشتی با پارامترهای واقعی بیولوژیکی با استفاده از اتصالات سیناپسی پویا به هم متصل می‌شوند.

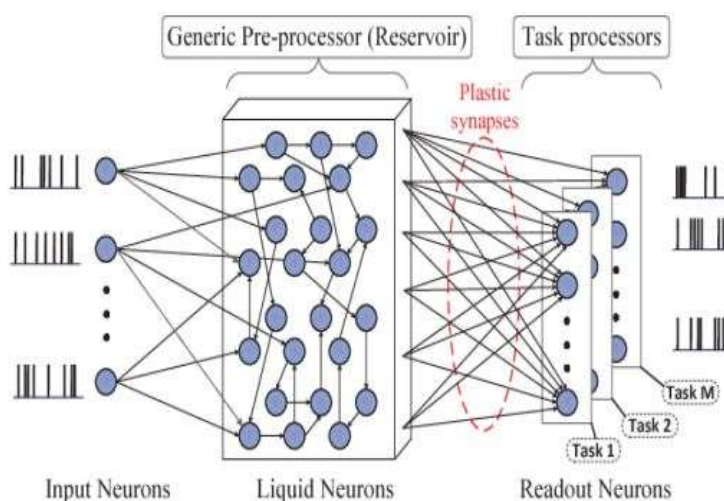
مدار بازخوانی نیز توسط چندین نورون LIF پیاده سازی می‌شود، با این حال، آنها شامل هیچ گونه اتصال درونی نیستند. در واقع این قسمت، مایع جریان ورودی با ابعاد پایین تر را به یک حالت داخلی با ابعاد

<sup>4</sup> Read out

<sup>5</sup> Spiking Neural Network

<sup>6</sup> Leaky Integrate and Fire Neuron

بالاتر تبدیل می‌کند و به عنوان ورودی به مدار بازخوانی بدون حافظه عمل می‌کنند که وظیفه تولید خروجی نهایی LSM را بر عهده دارد. شکل ۱ ساختار عمومی LSM را نشان می‌دهد.



شکل ۱-۱ ساختار عمومی LSM

## (۲-۲) سازماندهی گزارش

ادامه این گزارش به صورت زیر سازمان‌دهی شده است. در فصل دوم به بررسی نحوه آموزش در سه نوع مختلف پیاده سازی LSM ها می‌پردازیم. همچنین، در فصل سوم به اجزای LSM را برای کاربردی در پردازش فیلم بررسی می‌کنیم و نوع جدیدی از LSM ها که قابلیت اجرا توسط GPU را معرفی می‌کنیم. در فصل چهارم به محدودیت‌های انرژی در LSM ها می‌پردازیم. همچنین، در فصل پنجم LSM های مبتنی بر Memristor را مورد ارزیابی قرار می‌دهیم. سپس در فصل ششم به مخازن هوشمند با استفاده از بهینه‌سازی تکاملی می‌پردازیم.

## فصل دوم

### معماری‌های ماشین حالت مایع

## ۲-۱) مقدمه

مفهوم LSM ناشی از ماهیت تطبیق پذیری نئوکورتکس<sup>۷</sup> است. نئوکورتکس بخش کلیدی مغز پستانداران است و از طریق شبکه های نورون، عملکردهایی مانند ادراک حسی، تولید فرمان حرکتی، استدلال فضایی و تفکر آگاهانه را کنترل می کند. عملکرد نئوکورتکس بر اساس تشکیل شش لایه به هم پیوسته نورون است که به طور متوالی در یک دوره زمانی طولانی تولید می شوند.

تمرکز این تحقیق بررسی اهمیت یادگیری دسته‌ای (آفلاین) در مقابل یادگیری آنلاین بر روی LSM است. در این راستا، مدل LSM با استفاده از سه مقاله مختلف مورد بررسی قرار می گیرد و شرح عملکرد LSM، نحوه کار و نحوه آموزش آن و نتایج روش یادگیری دسته‌ای و آنلاین در کتاب را پوشش می دهد.

## ۲-۲) معماری پیشنهادی Jin برای LSM

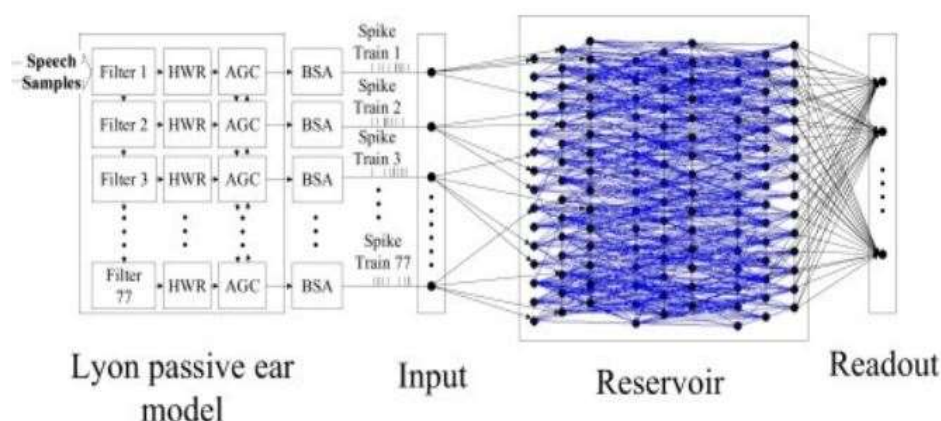
این مدل پیشنهادی شامل سه بخش اصلی LSM یعنی لایه ورودی، مخزن و بازخوانی می شود. سیگنال های ورودی این مدل LSM بر اساس تشخیص گفتار است. سیگنال ها از طریق سیگنال های گفتاری پیش پردازش شده توسط یک مدل گوش غیرفعال لیون تولید می شوند. سپس، سیگنال های تولید شده متعاقباً از طریق الگوریتم Bens Spiker (BSA)، الگوریتمی برای تبدیل مقادیر آنالوگ به قطارهای spike منتقل می شوند. BSA برای تولید قطارهای spike در شکل ۲ نشان داده شده است.

این دو مرحله برای پردازش سیگنال های ورودی اساسی هستند. در وهله اول، سیگنال، که قطار سنبله  $u(t)$  است، با پاسخ های LSM مخلوط شده که در آن سیگنال ها به حالت ها با ابعاد بالاتر تبدیل می شوند. مخزن از طریق سیناپس پلاستیکی در فاز دوم به بازخوانی متصل می شود. نورون بازخوانی در هر زمان  $t$  از مخزن جریان خالص داده شده مقدار زیر را دریافت می کند:

$$l_0(t) = \sum w_{oi} \cdot f_i(t) = \sum w_{oi} \cdot f_i[u(t)] \quad (1)$$

که  $f_i(t)$  پاسخ نورون  $i$ ام در مخزن است و  $w_{oi}$  وزن سیناپسی بین نورون  $i$ ام مخزن و نورون بازخوانی است. جریان خالص یکپارچه در بازه  $[0, T]$  برابر است با:

<sup>7</sup> Neocortex



شکل ۱-۲ سیستم تشخیص گفتار مبتنی بر LSM.

$$\begin{aligned} \int_{\square}^T I_o(t) &= \Sigma w_{oi} \cdot \int_0^T f_i(t) \\ &= \Sigma w_{oi} \int_0^T f_i[u(t)] \cdot \end{aligned} \quad (2)$$

مفهوم فوق این است که نورون بازخوانی به عنوان دسته‌بند خطی پاسخ‌های مخزن در نظر گرفته می‌شود، زیرا جریان خالص یکپارچه از نورون‌های بازخوانی ترکیبی خطی از خروجی‌های یکپارچه از نورون‌های مخزن است.


## ۳-۲ معماری پیشنهادی Azambuja برای LSM

در این روش طراحی LSM بر اساس انعطاف پذیری کوتاه مدت<sup>۸</sup> (STP) است که اساساً با تغییرات دینامیکی در بازده سیناپسی در یک دوره زمانی مرتبط است. STP به تغییرات سریع و برگشت پذیر قدرت سیناپسی ناشی از فعالیت اسپایکینگ پیش سیناپسی اشاره دارد و در مقیاس‌های زمانی از میلی ثانیه تا چند ثانیه رخ می‌دهد. اسپیک‌های پیش سیناپسی یا منجر به تسهیل در جایی که قدرت سیناپسی افزایش می‌یابد، می‌شوند یا در جایی که قدرت سیناپسی کاهش می‌یابد باعث افسردگی

<sup>۸</sup> Short Term Plasticity

می‌شود. تسهیل و افسردگی به وسیله پویایی کلسیم پیش سیناپسی، تخلیه یا دوباره پر شدن وزیکول‌ها<sup>۹</sup> در پایانه‌های پیش سیناپسی واسطه انجام می‌شود.


Azambuja و همکاران یک لایه انتزاعی از نورون‌های LIF را به عنوان ورودی در نظر گرفتند که مستقیماً به مخزن تزریق می‌شوند. لایه ورودی مجازی از ۳۰۰ نورون تشکیل شده بود که به ۶ گروه تقسیم شدند. در این راستا، توزیع گاوسی که اساساً به عنوان مدولاتور عمل می‌کند، لایه ورودی مجازی و مخزن را به هم متصل می‌کند که وزن‌های بین نورون‌های پیش سیناپسی و پس سیناپسی را تعدیل می‌کند و مقدار انحراف استاندارد پیش‌فرض را تعدیل می‌کند، از این رو هر اتصال ورودی ایجاد یک افزونگی می‌کند. مخزن نیز با استفاده از ۶۰۰ نورون LIF ایجاد شده (یک ساختار ۳ بعدی با اندازه ۲۰ در ۵) که ۸۰٪ نورون‌های تحریکی و ۲۰٪ نورون‌های بازدارنده هستند. در شکل ۳ این موضوع به خوبی نشان داده شده است.



شکل ۳-۲ بصری‌سازی بخش مایع LSM: مربع‌های قرمز نورون‌های تحریک‌کننده را نشان می‌دهند در حالی که الماس‌های آبی نورون‌های بازدارنده را نشان می‌دهند. خطوط قرمز پیوسته اتصالات تحریکی و خطوط آبی تیره بازدارنده هستند

<sup>۹</sup> Vesicles

نورون‌های بازخوانی فضای با ابعاد بالا تولید شده از مخزن جمع‌آوری را می‌کنند و با استفاده از یک دسته‌بندی خطی به شکل خطی تفسیر می‌کنند. در واقع، این مدل LSM یک کنترل کننده بازوی ربات بیومیمتیک با اتصالات بازخورد عمقی از نورون‌های خواندنی به ورودی‌ها است. شکل ۴ معماری کلی کنترل کننده بازو را نشان می‌دهد.



شکل ۴-۳ ساختار کنترل کننده بازو  $X.Y$  مختصات موضع نهایی هستند. همچنین،  $T1$  و  $T2$  گشتاورهای دستوری هستند و  $e1$  و  $e2$  نیز زوایای کنونی می‌باشند.

## ۴-۲ معماری پیشنهادی Avesani برای LSM

این مدل با هدف پرداختن به وظیفه کدگشایی تابع پاسخ همودینامیک<sup>۱</sup> (HRF) بدون مشکلات مرتبط با مدل‌هایی همچون آنالیز الگوی چند متغیره<sup>۱۱</sup> (MVPA) و ماشین بردار پشتیبان (SVM) پیشنهاد شده است. در این مدل، سیگنال ورودی  $x(t)$  از توالی محرک تشکیل شده است که اساساً سیگنال وابسته به سطح اکسیژن خون<sup>۲</sup> (BOLD) نامیده می‌شود.

<sup>1</sup> Hemodynamics Response Function


<sup>1</sup> Multivariate Pattern Analysis

<sup>1</sup> Blood Oxygenation Level Dependent

مخزن در این مدل یک سیستم غیر خطی با شبکه‌ای از نورون‌های مصنوعی است که به صورت بازگشتی محاسبه می‌شوند و اساساً از آن برای کدگذاری غیرخطی جریان ورودی با ثبت رویدادهای گذشته و تبدیل به یک وضعیت فعالیت داخلی با ابعاد بالا استفاده می‌شود. برعکس، بازخوانی (کدگشا) اطلاعات زمانی را از مخزن بازیابی کرده و آن را به یک خروجی سری زمانی تبدیل می‌کند. محاسبات اساسی شبکه‌های عصبی بازگشتی که مخزن را هدایت می‌کند به صورت زیر بیان می‌شود:

$$\begin{aligned} S(t) &= L(x).S(t-1) \\ Y(t) &= D(S(t)) \end{aligned} \quad (3)$$

که در آن حالت شبکه داخلی  $S$  در زمان  $t$  توسط اپراتور  $L$  ایجاد می‌شود که مقدار ورودی  $x$  را به شبکه در زمان فعلی  $t$  با حالت داخلی قبلی در زمان  $t-1$  ادغام می‌کند.  $D$  تابع آشکارساز است که معمولاً با استفاده از یک الگوریتم شفاف سازی یا رگرسیون آموزش دیده با مکانیسم‌های یادگیری ساده پیاده سازی می‌شود.



شکل ۴-۵ شبکه محاسباتی مخزن. مخزن یک جریان داده ورودی چند بعدی  $x(t)$  را پردازش می‌کند که یک سری حالت داخلی  $S(t)$  با ابعاد بالا ایجاد می‌کند. همزمان رمزگشاها تابع خروجی چند بعدی  $y(t)$  مورد نیاز را بر اساس حالات داخلی تولید شده تولید می‌کنند.

## ۵-۲ ارزیابی عملکرد مدل‌های مختلف LSM

مدل Jin LSM عملکرد و استحکام خود را بر روی تشخیص گفتار متمرکز کرده است. در این مدل قانون یادگیری بر اساس اصل Hebbian اتخاذ شده است که در آن هدف از فرآیند یادگیری تنظیم نورون‌های خوانده شده در راستای سطح مطلوب اعلام شده و همچنین تنظیمات بعدی وزن‌های



سیناپسی می‌باشد. در این مدل هر قطار از اسپایک‌های ورودی تولید شده در مرحله پیش پردازش به چهار نورون مخزن که به طور تصادفی انتخاب شده از طریق سیناپس ها با وزن ثابت ارسال می‌شوند.

وزن‌ها به طور تصادفی در محدوده دیجیتالی  $W_{min}$  و  $W_{max}$  انتخاب می‌شوند، که  $W_{min}$  و  $W_{max}$  به ترتیب حداکثر و حداقل وزن‌های سیناپسی مورد استفاده در شبیه‌سازی هستند. سیناپس های پلاستیکی نورون های مخزن را به طور کامل به هر نورون بازخوانی متصل می‌کنند و وزن آن‌ها به طور تصادفی بین  $W_{min}$  و  $W_{max}$  مقداردهی اولیه می‌شود. سیناپس های پلاستیکی توسط الگوریتم یادگیری اتخاذ شده آموزش داده می‌شوند.

عملکرد تشخیص با استفاده از LSM به طور تصادفی تولید شده شبیه سازی شد. LSM با توجه به نمونه‌ها برای پنج بار با مجموعه داده‌های مختلف آموزش و اعتبارسنجی شد. برای زمان  $i$  ام ( $i = 1, 2, 3, 4, 5$ ) گروه  $i$  ام برای تست و داده‌های باقی مانده برای آموزش استفاده می‌شود. تصمیم تشخیص پس از پخش هر نمونه گفتار آزمایشی گرفته می‌شود. در این زمان، نورون بازخوانی که اغلب شلیک می‌شود، برنده است و برچسب کلاس مرتبط با آن تصمیم دسته‌بندی LSM در نظر گرفته می‌شود. نهایتاً، پنج نرخ طبقه‌بندی به دست آمده در مرحله آزمایش به عنوان معیار نهایی عملکرد LSM به طور میانگین محاسبه می‌شود.

عملکرد مدل Azambuja تنها زمانی قابل تأیید است که وظیفه بازتولید چهار مسیر مجزا و یک کنترل کننده بازوی ربات بیومیمتیک اجرا شود.

آموزش چهار مجموعه آزمایش (مجموعه A، B، C و D) را در نظر گرفت و با استفاده از چهار مسیر مورد بررسی قرار می‌گیرد. در مجموع ۳۲۰ شبیه سازی ( $4 \times 4 \times 20$ ) برای آموزش بازخوانی‌ها انجام می‌شود. همچنین، آزمایشات برای هر مسیر با تغییر سطوح نویز و استفاده از STP انجام شد. STP به جای رفتار باند پهن مستقل از فرکانس، به انتقال اطلاعات کمک می‌کند، از این رو، نیاز به فیلتر کردن نویز زمانی که STP فعال است، وجود دارد. مقادیر پیش فرض برای  $i_{noise}$  و  $i_{offset}$  همان طور که در جدول ۱ نشان داده شده است بین مجموعه‌های A، B و C، D متفاوت است. همچنین متغیرهای ورودی دریافت کننده نویز افزایشی بین مجموعه‌های A، B و C، D متفاوت هستند زیرا سیستم بازخورد را از گشتاورها و زوایای اتصال بازخوانی‌های آموزش دیده در مجموع ۵۰ آزمایش جدید برای هر یک از

چهار مسیر مورد آزمایش قرار می‌گیرد. نتایج به‌عنوان پایه‌ای برای تأیید تأثیر فعال بودن یا نبودن STP در داخل مایع مورد استفاده قرار می‌گیرد.

مدل Avesani به وظیفه کدگشایی تابع پاسخ همودینامیک (HRF) متمرکز شده است. در این مدل، بازسازی سیگنال‌های وابسته به سطح اکسیژن خون (BOLD) آموزش و آزمایش می‌شود. هدف از مرحله آزمایش ارزیابی کیفیت مدل ایجاد شده و در نتیجه تأیید/رد وجود هر گونه رابطه بین محرک‌ها و سیگنال BOLD ثبت شده است. در مرحله آموزش، بخشی از داده‌ها به یک فرآیند یادگیری نظارتی داده می‌شود که پارامترهای خواندن/کدگشا را برای تولید وکسل<sup>۳</sup> سیگنال BOLD مورد نیاز با توجه به دنباله محرک‌ها تنظیم می‌کند. در طول مرحله آزمایش، بخشی از داده‌ها به عنوان یک مجموعه نگهدارنده برای ایجاد پاسخ BOLD مورد انتظار مربوط به مجموعه‌ای از محرک‌ها استفاده شد. سپس این با سیگنال BOLD واقعی برای تجزیه و تحلیل ارتباط مقایسه می‌شود.

جدول ۲-۱ پارامترهای پیش فرض مایع

Parameter	Value	Unit
Membrane time constant ( $\tau_m$ )	30.0	ms
Membrane capacitance ( $C_m$ )	30.0	nF
Synapse time constant (exc. - $\tau_{syn_e}$ )	3.0	ms
Synapse time constant (inh. - $\tau_{syn_i}$ )	6.0	ms
Refractory period (exc.)	3.0	ms
Refractory period (inh.)	2.0	ms
Membrane Threshold	15.0	mV
Membrane Reset	[13.8, 14.5]	mV
Membrane Initial	[13.5, 14.9]	mV
$i_{offset}$	[13.5, 14.5]	nA
$i_{noise} (\mu)$	0.0	nA
$i_{noise} (\sigma)$	1.0	nA
Transmission delay (exc.)	1.5	ms
Transmission delay (inh.)	0.8	ms


<sup>1</sup> Voxel

سیگنال‌های BOLD اصلی و مصنوعی تولید شده توسط LSM با استفاده از دو پارامتر که ریشه میانگین مربعات انحراف (RMSD) و همبستگی پیرسون<sup>۴</sup> هستند، تجزیه و تحلیل می‌شوند. زمانی که مقدار RMSD کم و مقدار همبستگی بالا باشد، دقت پیش‌بینی خوب مرتبط با کیفیت مدل بالا را نشان می‌دهد و نشان‌دهنده ارتباط یک وکسل برای یک کار شناختی معین است. برعکس، مقادیر RMSD بالا و مقادیر همبستگی پایین حاکی از دقت پیش‌بینی پایین است و این به این واقعیت اشاره دارد که مدل با داده‌ها مطابقت ندارد.

## ۶-۲ نتایج و بحث


عملکرد مدل LSM جین و لی با دو زیر مجموعه اضافی از مجموعه گفتار TI46، مجموعه داده کلمات گفتاری برای آموزش و ارزیابی الگوریتم‌های تشخیص گفتار مورد آزمایش قرار گرفت. شکل ۵ نرخ شناسایی LSM ها را در سه معیار متفاوت اتخاذ شده تجزیه و تحلیل می‌کند. سطح پیچیدگی ۳ تنظیم اصلی است که از ژانگ و همکاران (۲۰۱۵) اتخاذ شده است در حالی که سطح پیچیدگی ۲ تنظیم پیشنهادی این مدل بود. شکل ۶ به وضوح نشان می‌دهد که با کاهش پیچیدگی طراحی برای سه معیار اتخاذ شده، نرخ شناسایی کاهش می‌یابد. مفهوم این امر این است که عملکرد بهینه LSM در تشخیص گفتار به طور پیش‌فرض صرفاً به یادگیری آنلاین در مقابل یادگیری دسته‌ای بستگی دارد زیرا یادگیری دسته‌ای با ارائه اطلاعات قبلی پیچیدگی را کاهش می‌دهد.

<sup>۴</sup> Pearson Correlation



شکل ۵-۶ عملکرد طبقه بندی LSM در سه معیار اتخاذ شده به عنوان تابعی از پیچیدگی طراحی کاهش می‌یابد.

نتایج حاصل از آزمون t و لش انجام شده بر روی مدل Azambuja در شکل ۷ نشان داده شده است. مجموعه‌های A و C با STP فقط در طول مسیر ۲ (مثلاً) بهتر عمل کردند. برای مسیر ۳، نتایج برای همه مجموعه‌ها نزدیک به یکدیگر بود. برای مجموعه‌های A و B در مسیر ۴ تفاوت زیادی وجود نداشت. با این حال، ست D در اینجا نیز بهتر از C عمل کرد. نتایج برای مسیر ۱ همیشه زمانی که هیچ STP استفاده نمی‌شد بهتر بود. این مقاله به همان اندازه تأیید کرد که مدل LSM از طریق یادگیری آنلاین بهتر از یادگیری دسته‌ای عمل می‌کند.



شکل ۶-۷ عملکرد هزینه تاب خوردگی زمان پویا (DTW) با در نظر گرفتن مسیرها به صورت جداگانه. هرچه هزینه DTW کمتر باشد، نتایج بهتری حاصل می‌شود

عملکرد مدل LSM که توسط Avesani پیشنهاد شده است با همبستگی رفتار مدل بر اساس الگوی پیش‌بینی‌شده و مشاهده‌شده مورد تجزیه و تحلیل قرار گرفت. نتایج کارایی بالایی را برای داده‌های واقعی و سیگنال BOLD مصنوعی نشان داد که در آن وکسل‌ها به ترتیب ۱۰۰٪ و ۹۷٪ به درستی تعیین شدند. این نشان می‌دهد که نقشه‌های مغزی را می‌توان با رویکردهای داده‌محور تولید کرد، بدون نیاز به دانش قبلی در مورد HRF مورد انتظار که در غیر این صورت به عنوان یادگیری دسته‌ای/آفلاین شناخته شود.

یکی از جنبه‌های مهم که در آموزش و آزمایش این مدل‌ها مشاهده شد این است که عملکرد بهینه LSM از طریق یادگیری آنلاین به جای یادگیری دسته‌ای/آفلاین که در آن همه داده‌ها در دسترس هستند، به دست می‌آید. در یادگیری آفلاین، داده‌ها نمونه به نمونه پردازش می‌شوند و پارامترها در هر نمونه جدید به روز می‌شوند. همچنین، یادگیری آفلاین فرآیند یادگیری سریع‌تری را تسهیل می‌کند و زمانی مناسب است که داده‌ها با زمان تغییر می‌کنند یا زمانی که از قبل به همه داده‌های آموزشی دسترسی وجود ندارد. با این حال، شایان ذکر است که یادگیری آنلاین می‌تواند باعث ایجاد خطاهای باقیمانده در هنگام برخورد با نمونه‌های پرت شود.

## فصل سوم

### ماشین حالت مایع موازی شده برای تشخیص اقدام غیرعمدی

### ۳-۱) انگیزه و طرح مسئله

برای توانمند سازی استقرار الگوریتم‌های پیشرفته هوش مصنوعی بر روی پلتفرم‌های تعبیه شده پایین‌رده برای حل مشکلات بلادرنگ، موج جدیدی از علاقه‌ها به سمت توسعه سیستم‌های نورومورفیک الهام گرفته از مدل‌های زیستی هدایت شده‌اند. این سیستم‌ها تکنیک‌های پردازش اطلاعات عصبی مورد استفاده در مغز انسان را تقلید می‌کنند و به محققان این امکان را می‌دهند که سیستم‌های عصبی را مستقیماً در سخت‌افزار شناسایی کنند. این پتانسیل زیادی برای توسعه الگوریتم‌های محاسباتی سبک برای مسائل بلادرنگ ارائه می‌دهد. شبکه‌های عصبی مورد استفاده در این سیستم‌ها را شبکه‌های عصبی Spiking (SNN) نیز می‌نامند. برخلاف نورون‌های غیر اسپایکینگ که در شبکه‌های عمیق معمولی مانند شبکه‌های عصبی کانولوشن (CNN) و شبکه‌های عصبی تکراری (RNN) استفاده می‌شوند، SNN‌ها از نورون‌هایی استفاده می‌کنند که به جای انتشار مقادیر آنالوگ، با استفاده از اسپایک‌ها (از نظر ریاضی به عنوان تابع دلتای دیراک نشان داده می‌شوند) ارتباط برقرار می‌کنند. با این حال، سیستم‌های عصبی نورومورفیک اغلب در مقایسه با هم‌تایان یادگیری عمیق خود از عملکرد ضعیف رنج می‌برند. این امر به ویژه به این دلیل اتفاق می‌افتد که توابع فعال سازی (توابع مرحله واحد) مورد استفاده در SNN‌ها غیرقابل تمایز هستند، که مانع استفاده از روش‌های یادگیری پس انتشار سنتی و شیب نزولی می‌شود. این امر برای کارهای پیچیده‌ای مانند فعالیت و تشخیص عمل از طریق ویدیو، که به‌طور یکپارچه توسط چارچوب‌های عمیق سنتی کاملاً نظارت شده انجام می‌شوند، چالش‌برانگیزتر می‌شود. با این حال، چارچوب‌های یادگیری عمیق مرسوم مخصوصاً (RNN) از نظر محاسباتی گران هستند و گاهی اوقات ناپایدار هستند (مشکلات گرادیان در حال محو شدن و انفجار)، که مانع استقرار آن‌ها در پلتفرم‌های تعبیه شده پایین می‌شود.

کار پیچیده‌ای مانند تجزیه و تحلیل داده‌های مکانی-زمانی یک زمینه در حال رشد برای محققان یادگیری عمیق است، اگرچه در مقایسه با تجزیه و تحلیل تصویر، صدا و متن کمتر مورد بررسی قرار گرفته است. این عمدتاً به دلیل پیچیدگی پردازش اطلاعات مورد نیاز برای انجام قابل توجهی روی داده‌های ویدیویی است. وظایفی مانند کنش و شناسایی فعالیت از ویدئو، استخراج ویژگی‌های مکانی و زمانی، انتزاع اطلاعات سطح بالا را می‌طلبد. علاوه بر این، استنباط اطلاعاتی مانند انگیزه‌ها یا مقاصد به تصویر کشیده

شده در یک ویدیو، سطح دیگری از پیچیدگی و سربار منابع محاسباتی را به الگوریتم‌ها اضافه می‌کند. این نه تنها مانع آموزش مدل‌های یادگیری عمیق می‌شود، بلکه از استقرار آن در دستگاه‌های پایانی کاربر نیز جلوگیری می‌کند.

الگوی مدل‌های محاسباتی که به عنوان محاسبات مخزن (RC) شناخته می‌شوند، نیز در زمان‌های اخیر توجه قابل توجهی را به خود جلب کرده است. الگوریتم‌های RC در ابتدا توسط دو گروه تحقیقاتی مستقل با عنوان ماشین حالت مایع (LSM) و شبکه حالت اکو (ESN) پیشنهاد شدند. الگوریتم‌ها سعی می‌کنند با این فرض که حتی یک RNN با وزن ثابت به‌طور تصادفی متصل شده، توانایی محاسباتی کافی برای نمایش داده‌های ورودی به یک فضای نهفته پراکنده با ابعاد بسیار بالا را داشته باشند، به طوری که داده‌های کلاس‌های مجزا تقریباً به‌طور خطی قابل تفکیک می‌شوند، تا مشکل آموزش شبکه‌های عصبی بسیار مکرر را دور بزنند. مدل LSM از SNN‌ها استفاده می‌کند در حالی که مدل ESN از نورون‌های غیر اسپایکینگ استفاده می‌کند.

مشکل اصلی که مانع رشد الگوریتم‌های محاسباتی مخزن مانند LSM می‌شود، ناتوانی در شبیه‌سازی نورون‌های spiking به شیوه‌ای موازی‌پذیر یا سازگار با GPU است. بنابراین، با در نظر گرفتن تمام مشکلات بیان شده، الگوریتمی را ارائه می‌کنیم که نورون‌های اسپایکینگ را به‌طور کلی موازی کند. نورون‌های اسپایکینگ موازی با نورون‌های اسپایکینگ سنتی یکسان عمل می‌کنند. این الگوریتم بیشتر برای پیاده‌سازی یک LSM موازی توسعه یافته است. در نهایت، ما توانایی محاسباتی SNN‌های نورومورفیک الهام گرفته از مدل‌های زیستی را بر اساس مدل LSM موازی، برای پیش‌بینی اقدامات ناخواسته در فیلم‌ها ارزیابی می‌کنیم.

## ۲-۳) تجزیه و تحلیل ویدئو و تشخیص عمل

هدف اصلی ما از پیش‌بینی اقدامات تصادفی/غیر عمدی در ویدیو، زیرمجموعه‌ای از دامنه بزرگ‌تری از تجزیه و تحلیل ویدیو است. تشخیص اشیاء از طریق ویدئوها تنها شروع در این زمینه بود. ذاتاً، اشیاء دارای ماهیت ماندگاری شفاف در فرم در فریم‌های ویدیویی هستند. با این حال، تشخیص عمل، که شامل تغییرات پویا در شکل محتوا در یک ویدیو است، یک کار چالش برانگیزتر است. در گذشته، طبقه‌بندی کنش‌های ویدیویی از توصیفگرهای ویژگی برای فریم‌های ویدیویی معین استفاده می‌کرد. با این حال، با



ظهور CNN های عمیق، ویژگی های قابل آموزش ترند شد. در نتیجه، تکنیک های نمایش ویژگی های آموزنده مانند ادغام اطلاعات بصری، سی ان ان های سه بعدی و سی ان ان های دوطرفه تبدیل به پیشرفته ترین فناوری ها شدند. علاوه بر این، محققان LSTM را بر روی ویژگی های بصری استخراج شده توسط CNN و ترکیب حسگرهای حرکتی با ویژگی های بصری پیشنهاد کرده اند.

### ۳-۳ محاسبات مخزن

پیشرفت های اخیر در یادگیری عمیق، که برای پلتفرم های محاسباتی سطح بالا مناسب است، معمولاً هنگام در نظر گرفتن پلتفرم های تعبیه شده پایین رده، از مشکلات استقرار رنج می برند. محاسبات مخزن (RC) این مسئله را با دور زدن نیاز به آموزش شبکه های عصبی یا مخازن بسیار تکرار شونده برطرف می کند. اخیراً، شبکه های دریافت کانولوشن (CDN) برای انجام تشخیص فعالیت ویدئویی کارآمد قدرت و منابع محاسباتی پیشنهاد شده اند. CDN ها از CNN برای استخراج ویژگی ها از فریم های ویدئویی استفاده کردند و از یک ESN به عنوان مخزنی که دینامیک زمانی را ثبت می کرد، استفاده شد. علاوه بر این، یک مدل عمیق سلسله مراتبی LSM به همراه مدل های توجه برای حل مشکل تشخیص فعالیت از ویدیوی خودمحور ارائه شد. به غیر از فیلم ها، چندین اثر از ESN و LSM برای پردازش تصویر، تشخیص گفتار و حتی برای یادگیری تقویتی استفاده کرده اند. با این حال، LSM ها به دلیل پیشرفت های اخیر سخت افزار نورومورفیک، فرصت بیشتری نسبت به ESN ها ارائه می دهند. این سیستم ها شبکه های عصبی spiking را مستقیماً در سخت افزار پیاده سازی می کنند و هزینه شبیه سازی را به شدت کاهش می دهند.

### ۴-۳ نورون های اسپایکینگ

نورون های اسپایکینگ با مدل LIF پیاده سازی می شوند که با معادله زیر توضیح داده شده است:

$$\tau_m \frac{dV(t)}{dt} = -(V(t) - V_{rest}) + R_m I(t) \quad (4)$$

که  $V(t)$  پتانسیل غشایی یک نورون اسپیک در زمان  $t$  است، و  $V_{rest}$  پتانسیل غشایی در حال استراحت است که  $V(t)$  به آن واپاشی می کند، با نرخ واپاشی که توسط ثابت زمانی  $\tau_m$  کنترل می شود. مقاومت غشا به صورت  $R_m$  تعریف می شود و  $I(t)$  جریان ورودی آنی است. هنگامی که نورون جریان ورودی را

دریافت نمی کند ( $I(t) = 0$ )، پتانسیل غشاء با سرعتی متناسب با پتانسیل آنی آن تجزیه می شود تا زمانی که در  $V_{rest}$  مستقر شود. با این حال، هنگامی که  $V(t)$  به پتانسیل آستانه ( $V_{th}$ ) که همیشه بزرگتر از  $V_{rest}$  است) در دریافت سنبله های متوالی در یک پنجره زمانی کوتاه می رسد، نوروں با انتشار یک ولتاژ خروجی به بزرگی  $V_{spike}$ ، همانطور که در معادله زیر بیان شده است، افزایش می یابد:

$$V(t) = \begin{cases} V_{spike} & \text{if } V(t) \geq V_{th} \\ V(t) & \text{otherwise} \end{cases} \quad (5)$$

تابع فعال سازی (رابطه 5) ماهیت شرطی و غیرقابل تمایز دارد، به همین دلیل الگوریتم یادگیری مبتنی بر پس انتشار سنتی (که شامل تمایز زنجیره ای است) نمی تواند در شبکه های عصبی spiking استفاده شود. علاوه بر این، هنگامی که یک نوروں فعال می شود، وارد یک دوره نسوز برای گام های زمانی  $\tau_{ref}$  می شود، که در آن پتانسیل غشایی آن در  $V_{rest}$  ثابت می ماند. به طور کلی، برای شبیه سازی عددی، معادلات 4 و 5 با استفاده از عبارات شرطی کلاسیک، همانطور که در الگوریتم 1 توضیح داده شده است، پیاده سازی می شوند.

---

**Algorithm 1:** Generic implementation of a LIF neuron's state update routine

---

**Input:** Instantaneous current  $I(t)$

**Output:** Membrane potential at time =  $t$

**if** *refraction* is *False* **then**

$$V(t) = V(t-1) + \left[ \frac{-V(t-1) + V_{rest} + R_m I(t)}{\tau_m} \right] * \Delta t$$

**if**  $V(t) \geq V_{th}$  **then**

$$V(t) = V_{spike}$$

*refraction* = *True*

$$\text{counter} = \tau_{ref}$$

**else**

$$V(t) = V_{rest}$$

$$\text{counter} = \text{counter} - 1$$

**if** *counter* is 0 **then**

*refraction* = *False*

---

توجه داشته باشید که روال به روز رسانی پتانسیل غشاء، ارائه شده در الگوریتم 1، برای یک مرحله زمانی منفرد ( $\Delta t$ ) و برای یک نوروں منفرد اسپیکینگ ارائه شده است. با این حال، برای پیاده سازی شبکه های بزرگ که شامل هزاران نوروں اسپیکینگ هستند، چنین پیاده سازی عمومی فرآیند استنتاج شبکه را بسیار تکراری و زمان بر می کند. برای مقابله با این مشکل، الگوریتم به روزرسانی حالت نوروں (الگوریتم 1) را از

نظر عملیات بردار/ماتریس و تبدیل‌های نوع داده دوباره فرموله می‌کنیم. در این روش، برای یک لایه حاوی نورون‌های LIF اسپیکینگ L، بردار ولتاژ غشای L بعدی  $V(t)$  را برای مرحله زمانی فعلی به صورت زیر محاسبه می‌کنیم:

$$\Delta V(t) = \frac{-V(t) \oplus V_{rest} \oplus (I(t) \otimes R_m)}{\tau_m} \quad (6)$$

$$V(t) = V(t) \oplus (\Delta V(t) \otimes \Delta t) \quad (7)$$

که  $\oplus$  و  $\otimes$  به ترتیب ضرب و جمع یک مقیاس کننده را با هر عنصر یک بردار از نظر عنصر نشان می‌دهد.  $V_{rest}$  یک بردار بعدی L است که در آن همه عناصر  $V_{rest}$  هستند و  $I(t)$  بردار جریان ورودی است. برای انتقال اطلاعات مربوط به نورون‌های انکسار در گام‌های زمانی، از بردار شمارنده انکسار  $R_c(t)$  استفاده می‌کنیم. علاوه بر این، ما یک بردار دوتایی  $R_f$  را محاسبه می‌کنیم که نشان می‌دهد آیا یک نورون در حالت انکساری قرار دارد یا خیر، به صورت زیر:

$$R_f = \text{int}(\text{bool}(R_c(t))) \quad (8)$$

که

$$\text{bool}(x) = \begin{cases} \text{True}, & \text{if } x \neq 0 \\ \text{False}, & \text{if } x = 0 \end{cases} \quad (9)$$

$$\text{int}(x) = \begin{cases} 0, & \text{if } x = \text{False} \\ 1, & \text{if } x = \text{True} \end{cases} \quad (10)$$

ولتاژهای غشا را با استفاده از رابطه زیر به روز می‌کنیم.

$$V(t) = [(1 - R_f) \odot V(t)] \oplus (R_f \odot V_{rest}) \quad (11)$$

که  $\odot$  نشان دهنده ضرب عنصری است. رویداد S، که در آن پتانسیل غشایی یک نورون  $V(t)$  از قدر آستانه  $V_{th}$  عبور می‌کند، با استفاده از معادله ۱۲ تشخیص داده می‌شود، که  $[0]_L$  یک بردار L بعدی صفر را نشان می‌دهد.

$$S = \text{int} \left( \text{bool} \left( \left[ \max \left( [0]_L, \left[ V(t) \ominus V_{th} \right] \right) \right] \right) \right) \quad (12)$$

بردار  $N(t)$  حاوی خروجی لحظه‌ای کل لایه با استفاده از معادله ۱۳ محاسبه می‌شود. در نتیجه، هر عنصر در  $N(t)$  یا صفر خواهد بود یا یک اسکالر غیر صفر با اندازه  $V_{spike}$ . بنابراین، یک بردار بعدی  $L V_{spike}$  که تمام عناصر آن  $V_{spike}$  هستند، در محاسبه  $N(t)$  استفاده می‌شود.

$$N(t) = S \odot V_{spike} \quad (13)$$

پس از هر مرحله زمانی، بردار شمارنده انکسار  $R_c(t)$  برای نورون‌های در حال شکست با استفاده از معادله کاهش ۱۴ می‌یابد.

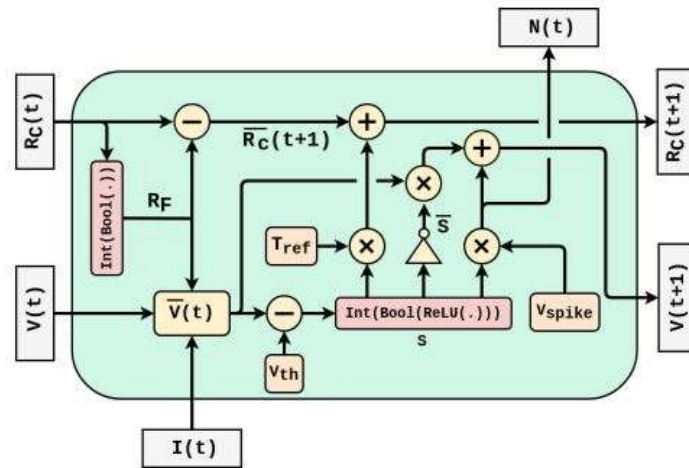
$$R_c(t+1) = R_c(t) \ominus R_f \quad (14)$$

سرانجام، در پایان هر مرحله زمانی،  $V(t+1)$  و  $R_c(t+1)$  برای مرحله زمانی بعدی با استفاده از معادله‌های ۱۵ و ۱۶ محاسبه می‌شود. نورون‌هایی که در گام زمانی فعلی افزایش یافته‌اند،  $R_c(t)$  را با قدر  $\tau_{ref}$  به روز می‌کنند، که نشان دهنده گذار از حالت عادی به حالت نسوز است. پس از گام‌های زمانی  $\tau_{ref}$ ، این نورون‌ها از دوره نسوز خارج می‌شوند.

$$V(t+1) = \left( (1 - S) \odot \bar{V}(t) \right) \oplus N(t) \quad (15)$$

$$R_c(t+1) = (S \otimes \tau_{ref}) \oplus R_c(t+1) \quad (16)$$

توجه داشته باشید که در فرمول‌های فوق، تمام بردارها  $L$  بعد هستند، با در نظر گرفتن یک لایه LIF که یک قطار سنبله با ابعاد  $L \times T_{ST}$  را پردازش می‌کند، که در آن  $T_{ST}$  طول زمانی قطار سنبله است. با این حال، می‌توان آن را با در نظر گرفتن ماتریس‌های ابعادی  $L \times B$  برای همه بردارهای حالت، که در آن  $B$  اندازه دسته ورودی است (با توجه به پردازش موازی قطارهای سنبله)  $B$  به راحتی تا حالت پیش‌بینی دسته‌ای مقیاس‌بندی کرد. شکل ۲ یک نمایش مدولار از معادلات ۳ تا ۱۳ را برای یک لایه حاوی  $L$  نورون LIF را نشان می‌دهد.



شکل ۸-۱ لایه LIF موازی شده: با استفاده از معادله های ۳-۱۳، یک لایه LIF موازی حاوی L نرون را می توان به صورت مدولار نشان داد.

### ۳-۵) تاخیر سیناپسی

در لایه مایع یک LSM، محاسبه در هر تکرار می تواند به صورت زیر بیان شود:

$$I_L(t) = [W_L * N(t-1)] + [W_{LI} * I_I(t)] \quad (17)$$

که  $I_L(t)$  جریان ورودی نهایی در زمان  $t$  برای تمام نرون های لایه مایع است،  $N(t-1)$  حالت قبلی لایه مایع و  $I_I(t)$  جریان ورودی آنی است که از لایه ورودی رسیده است. سپس از  $I_L(t)$  برای به روزرسانی وضعیت نرون های لایه مایع با استفاده از معادلات ۳-۱۳ انجام می شود. بنابراین، در این پیاده سازی عمومی، در نظر گرفته می شود که وقتی یک سنبله از هر نرون لایه مایع منشأ می گیرد، دقیقاً در تکرار بعدی به تمام نرون های پس سیناپسی دیگر می رسد. با این حال، با در نظر گرفتن یک محیط فیزیکی که در آن نرون های لایه مایع در آن قرار دارند، بی اهمیت است که زمان مورد نیاز سیگنال برای طی کردن طول های مختلف اتصالات متفاوت باشد. این مفهوم اتصالات با تاخیر را به ارمغان می آورد. الگوریتم ۲ روال به روز رسانی حالت را برای یک لایه مایع حاوی L نرون spiking که دارای تاخیر سیناپسی است را توصیف می کند، و شکل ۳ الگوریتم را به صورت شماتیک نشان می دهد.

**Algorithm 2:** LSM update routine with delayed synaptic connections

Input: Input spike-train of length  $T$

Output: Activation of liquid layer

**for**  $t \rightarrow T$  **do**

$$N_s^{prev} = W_L \odot Buffer.pop()$$

$$N(t-1) = \sum N_s^{prev}, \text{ across columns}$$

$$I_L(t) = N(t-1) + [W_{LI} * I_I(t)]$$


$$N(t) = update(I_L(t))$$

// Stack  $N(t)$   $L$  times across columns

$$\overline{N(t)} = [N^T(t), N^T(t), \dots, N^T(t)]$$

$$Buffer.push(\overline{N(t)})$$

$$activation[t] = N(t)$$



شکل ۹-۲ به روز رسانی وضعیت LSM: زوال به روز رسانی وضعیت LSM ذکر شده در الگوریتم ۲ در این نمودار شماتیک به تصویر کشیده شده است.  $I(t)$  نشان دهنده جریان ورودی و  $N(t)$  وضعیت لایه مایع را برای هر مرحله زمانی نشان می‌دهد.

### ۳-۶) بازخوانی مکانی-زمانی

برخلاف مدل‌های عمومی LSM، که در آن فعال سازی مکانی-زمانی لایه مایع فشرده می‌شود تا یک بردار میانگین تعداد سنبله یک‌بعدی و به دنبال آن یک شبکه کاملاً متصل برای عمل خواندن به دست آید، ما

یک لایه سه بعدی CNN خواندنی طراحی می کنیم. در مرحله اول، ما اطلاعات فضایی نوروها را با تغییر شکل بردارهای حالت لایه مایع یک بعدی به دست آمده به شکل مکعبی ۳ بعدی آن حفظ می کنیم. این به این دلیل است که فرض می کنیم آرایش فضایی نوروها حاوی اطلاعات مهمی است زیرا اتصالات در لایه مایع با استفاده از یک تابع احتمال فضایی اولیه محاسبه می شوند. ثانیاً، ما فعال سازیها را در امتداد محور زمان به طور کامل فشرده نمی کنیم. در عوض، ما میانگین بردارهای حالت لایه مایع را برای هر گام زمانی  $W$  انجام می دهیم، به طوری که  $T=W$  یک عدد صحیح است، که در آن  $T$  تعداد کل مراحل زمانی است که برای آنها فعال سازی لایه مایع به دست می آید. این یک نمایش غنی تر از فعال شدن لایه مایع در مکان و زمان ایجاد می کند.

### ۷-۳) آزمایش مدل و نتیجه گیری

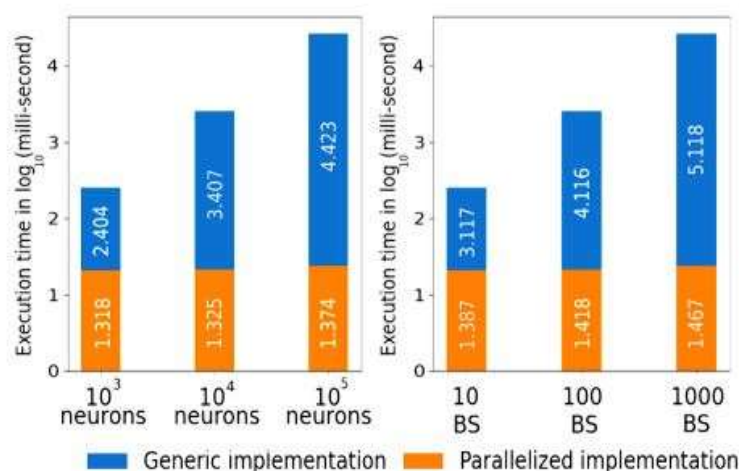
نتایج به دست آمده توسط مدل PLSM ما در مجموعه داده Oops به شدت تحت تاثیر انتخاب ماژول خاص و انتخاب هایپرپارامترهای شبکه است. جدول ۳ فرسایش ماژول های مختلف مورد استفاده در معماری کلی ما را نشان می دهد. علاوه بر این، ما با پارامترهای مختلف بخش های قابل توجهی از معماری آزمایش می کنیم تا مدل پیشنهادی خود را توجیه کنیم.

جدول ۳-۱ حذف ماژول های مختلف با استفاده از ۷ تنظیمات مختلف برای مجموعه داده Oops.

Modules	1st	2nd	3rd	4th	5th	6th	7th
Backbone : DenseNet-161	-	-	✓	-	✓	-	✓
Backbone : ResNet-50	✓	✓	-	✓	-	✓	-
Auto-Encoder for dimension reduction	-	✓	✓	✓	✓	✓	✓
Using mean spike count as reservoir activation	✓	✓	✓	-	-	-	-
3D-CNN on spatio-temporal activation	-	-	-	✓	✓	✓	✓
Semantic Masking	-	-	-	-	-	✓	✓
Validation accuracy	39.3%	45.7%	49.5%	56.2%	57.6%	64.3%	66.3%

**موازی سازی:** ما اهرم قابل توجهی را که با استفاده از شبکه های عصبی spiking موازی به دست آمده را بر خلاف اجرای عمومی ارزیابی می کنیم. شکل ۴ (سمت چپ) افزایش قابل توجه در سرعت پردازش را برای لایه ای از نوروهای spiking LIF نشان می دهد. همانطور که در بخش ۳.۱ ذکر شد، پیاده سازی لایه های SNN موازی شده ما می تواند به راحتی برای انجام در حالت پیش بینی دسته ای ارتقا

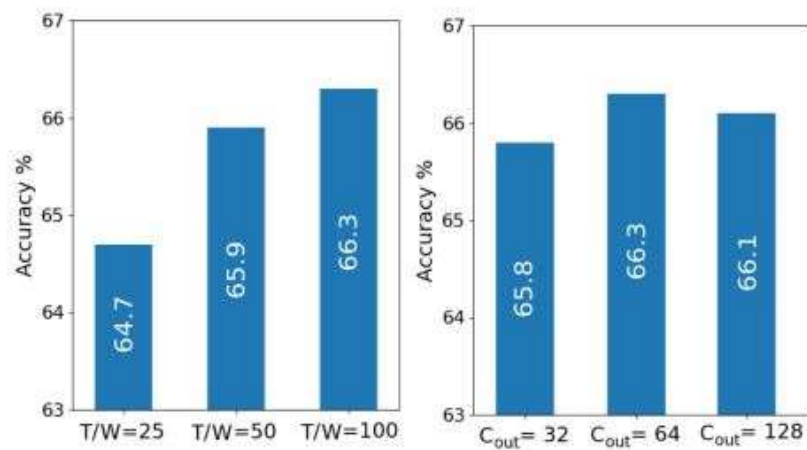
یابد. این با افزودن بعد دیگری به تمام بردارهای حالت لایه SNN به دست می آید. افزایش سرعت پردازش هنگام استفاده از حالت پیش‌بینی دسته‌ای برای لایه‌ای از ۵۰۰ نورون LIF در شکل ۴ (راست) ترسیم شده است. نتایج برای یک قطار سنبله ورودی با ۱۰۰ گام ارائه شده است. از نمودارها مشخص است که با افزایش تعداد نورون‌ها/اندازه دسته‌ای، اجرای SNN موازی شده ما با یک حاشیه بزرگ از الگوریتم اجرای عمومی بهتر عمل می‌کند. به دلیل این سرعت محاسباتی است که مدل PLSM ما قادر به آموزش بر روی یک مجموعه داده بسیار بزرگ مانند Oops در مدت زمان قابل حمل بود.



شکل ۱۰-۳ نتایج مقایسه‌ای از موازی‌سازی: نورون‌های LIF موازی شده ما با چندین مرتبه بزرگی برای یک لایه واحد با افزایش نورون‌ها (سمت چپ) بهتر از نورون‌های LIF عمومی عمل می‌کنند. ما همچنین یک لایه از ۵۰۰ نورون LIF را برای ارزیابی عملکرد در حالت دسته‌ای با اندازه‌های مختلف (BS) اجرا می‌کنیم (سمت راست).

**دقت زمانی:** ما از یک لایه خواندن کانولوشنال سه بعدی برای طبقه بندی کلیپ‌ها از ویژگی‌های استخراج شده توسط لایه مایع PLSM استفاده می‌کنیم. به طور معمول، ویژگی‌های به دست آمده از لایه مایع در طول محور زمانی میانگین می‌شوند تا میانگین تعداد سنبله به دست آید. با این حال، استفاده از سی‌ان‌ان سه بعدی ما را قادر می‌سازد تا از ویژگی‌های توزیع شده زمانی با چیدن آنها در محور کانال ورودی CNN استفاده کنیم. شکل ۵ (سمت چپ) تغییر در دقت طبقه بندی را با توجه به مقادیر مختلف  $T=W$  نشان می‌دهد. مشاهده می‌شود که حفظ ویژگی‌ها در طول زمان عملکرد کلی را افزایش می‌دهد.





شکل ۴-۱۱ دقت زمانی و حفظ ویژگی‌ها در طول زمان عملکرد PLSM را افزایش می‌دهد (سمت چپ). برای  $T=W=100$ ، آزمایش‌ها نشان می‌دهند که  $C_{out}=64$  نتیجه بهینه را ارائه می‌کند (راست).

## فصل چهارم محدودیت‌های انرژی در ماشین‌های حالت مایع

## ۴-۱) هوش مصنوعی در دستگاه‌های لبه‌ای

گنجاندن هوش مصنوعی در لبه برای برنامه‌هایی که نمی‌توانند هزینه‌های بارگذاری محاسبات را به یک منبع خارجی پشتیبانی کنند، حیاتی است. به عنوان مثال، دوربین‌های هوشمندی که برای شناسایی مزاحمان خانگی به کار می‌روند به یک اتصال بی‌سیم پرسرعت نیاز دارند و می‌توانند از زمان جمع‌آوری ویدیو تا دریافت نتیجه طبقه‌بندی از یک منبع ابری تا ۵ ثانیه تأخیر داشته باشند، که ممکن است برای برخی از برنامه‌ها غیرقابل قبول باشد. با این حال، انتقال هوش مصنوعی به لبه می‌تواند دشوار باشد، زیرا بسیاری از دستگاه‌های مجهز به اینترنت در لبه بدون سیستم‌عامل کار می‌کنند، که می‌تواند منجر به افزایش زمان یکپارچه‌سازی با چارچوب‌های محاسباتی معمولی هوش مصنوعی مانند TensorFlow شود. علاوه بر این، ادغام هوش مصنوعی در دستگاه‌های لبه نیز نیازمندی‌های محاسباتی آن‌ها را افزایش می‌دهد و به شتاب سخت‌افزاری یا واحد پردازش بهبودیافته نیاز دارد که هر دو ممکن است هم هزینه و هم مصرف انرژی دستگاه را افزایش دهند. ادغام هوش مصنوعی در دستگاه‌های لبه‌ای با انرژی محدود، مانند تلفن‌های همراه با باتری، نیز مشکل ایجاد می‌کند زیرا افزایش هزینه‌های محاسباتی باعث کاهش عمر باتری دستگاه‌ها می‌شود، که باعث تخلیه محاسبات به منابع خارجی می‌شود. در سیستم‌های بیولوژیکی، جایی که منابع انرژی نیز محدود است، محدودیت‌های انرژی برای حفظ پایداری مدارهای عصبی مورد استفاده قرار می‌گیرند. به عنوان مثال، نشان می‌دهد که اختلالات در متابولیسم انرژی مغز به ایجاد و حفظ تشنج‌های صرع کمک می‌کند. در این کار، ما اثرات محدودیت‌های انرژی متابولیک را بر روی یک شبکه عصبی مصنوعی در حال افزایش مدل‌سازی می‌کنیم و اثرات آن‌ها را بر عملکرد شبکه در هنگام انجام وظایف محاسباتی تحلیل می‌کنیم.

در مغز انسان تصور می‌شود که متابولیسم انرژی توسط سلول‌های گلیال<sup>۱</sup> تنظیم می‌شود که شایع‌ترین آنها آستروسیت<sup>۲</sup> است. در حال حاضر تصور می‌شود که اکثر گلوکز، منبع انرژی اولیه مغز، که در مغز مصرف می‌شود، از طریق سلول‌های گلیال انجام می‌شود. برای تسهیل جذب گلوکز، آستروسیت‌ها خود را به رگ‌های خونی در مغز متصل می‌کنند. آنها سپس متابولیت‌های انرژی را که ایجاد می‌کنند به نورون‌هایی که

<sup>۱</sup> Glial

<sup>۲</sup> Astrocyte

آنها را برای انرژی مصرف می کنند، توزیع می کنند. آستروسیت ها همچنین ذخیره ای از گلیکوژن را حفظ می کنند که می تواند به عنوان منبع انرژی ذخیره ای برای تامین نورون ها عمل کند. این عملکرد سلول های گلیال، جایی که آنها برای استخراج انرژی از خون، حفظ ذخیره انرژی و تامین انرژی به نورون ها خدمت می کنند، همان چیزی است که در این کار مورد بررسی قرار خواهد گرفت.

## ۴-۲) هوش مصنوعی در دستگاه های لبه ای

کارهای دیگر، مانند تأثیر محدودیت های انرژی بر شبکه های عصبی مصنوعی را بررسی کرده اند. به طور مثال در یک رویکرد، به هر یک از نورون های spiking مخزن انرژی خود را می دهند، که به تدریج در طول زمان دوباره پر می شود. هر بار که یک نورون بلند می شود، در صدی از مخزن انرژی خود را تخلیه می کند. هنگامی که مخزن انرژی آن تخلیه می شود، نورون از اسپک شدن جلوگیری می کند. نویسندگان شبکه را با دادن یک سوگیری به هر نورون و تجزیه و تحلیل فعالیت شبکه و انرژی باقی مانده در طول زمان ارزیابی کردند. آنها دریافتند که نوسانات هم در نرخ اسپک و هم در انرژی شبکه وجود دارد، مشابه نوسانات مشاهده شده در فعالیت بیولوژیکی مغز.


در یک رویکرد دیگر، توسعه ای را برای مدل نورون Izhikevich ایجاد شد که عرضه انرژی به نورون توسط یک سلول گلیال را با یک سلول گلیال در هر نورون مدل سازی می کند. آنها دریافتند که هنگام نمونه برداری از تعدادی از اینها در یک شبکه، فعالیت اسپک مشابهی با پدیده ای که در مغز انسان شناسایی کرده اند مشاهده شد.

همچنین کار با شبکه های آموزشی با محدودیت های انرژی اعمال شده است. محققان دریافتند می توانند وزنه ها را در یک شبکه به گونه ای آموزش دهند که شبکه در برخی از محدودیت های انرژی مشخص عمل کند، با نورون هایی که برای مصرف انرژی هم از ادغام ورودی ها و هم از تولید اسپک ها ساخته شده اند. آنها دریافتند که بدون توجه به تعداد نورون ها یا اتصالات سیناپسی موجود در شبکه می توانند این کار را انجام دهند.

### ۳-۴) محدودیت‌های انرژی

محدودیت‌های انرژی فقط به مخزن LSM اضافه می‌شود. به هر کدام از نورون‌های مخزن انرژی اختصاص داده می‌شود و هر بار که نورون شلیک می‌کند از آن حوضچه انرژی کم می‌شود. علاوه بر آن، ما به نورون‌های متعدد اجازه می‌دهیم که یک مخزن انرژی را به اشتراک بگذارند. در این حالت، مخزن انرژی دارای حداکثر انرژی است که به صورت خطی با تعداد نورون‌های متصل به آن مرتبط است. به عنوان مثال، یک نورون با یک حوضچه منفرد برای داشتن حداکثر انرژی ۱ واحد (خودسرانه) و یک استخر با ۱۰ نورون با حداکثر انرژی ۱۰ واحد ساخته شده است. توجه داشته باشید که در شبیه‌سازی‌های ما، اندازه‌های استخر مخلوط نشده اند و هر حوضچه به همان تعداد نورون متصل به آن خواهد بود.

در مورد نورون‌های متعدد در هر استخر، نورون‌ها بر اساس فاصله به استخر اضافه می‌شوند. برای مقداردهی اولیه، یک مخزن انرژی در همان مکان یک نورون تصادفی قرار می‌گیرد که هنوز حوضچه‌ای ندارد. سپس نزدیک‌ترین نورون‌هایی که به هیچ استخری متصل نیستند به آن حوضچه متصل می‌شوند تا تعداد نورون‌های مورد نظر به حوضچه متصل شوند. این کار تا زمانی تکرار می‌شود که تمام نورون‌های مخزن به یک استخر انرژی متصل شوند. تصویری از یک مخزن با ۴ نورون در هر مخزن انرژی را می‌توان در شکل ۲ مشاهده کرد.



شکل ۱۲-۱ نمودار مخزن ساخته شده با استخرهای انرژی به تصویر کشیده شده است. کره‌های تیره رنگ (بنفش) نورون‌های LIF هستند. فلش‌های خاکستری اتصالات سیناپسی هستند. بیضی‌های شفاف روشن‌تر (سبز) حوضچه‌های انرژی مشترک بین نورون‌های محصور شده را نشان می‌دهند.

هر بار که یک نورون مخزن شلیک می‌کند، مقداری انرژی را از مخزن انرژی متصل خود کم می‌کند. این مقدار از شبیه‌سازی به شبیه‌سازی متفاوت بود. اگر مخزن انرژی انرژی کافی نداشته باشد، نورون از شلیک منع می‌شود. هر مخزن انرژی در هر مرحله از شبیه‌سازی انرژی را با نرخ ثابتی تولید می‌کند. این بر روی ۵ درصد از حداکثر انرژی یک استخر در هر گام تنظیم شده است. علاوه بر این، اگر انرژی یک مخزن انرژی تمام شود، پتانسیل غشایی انباشته شده هر نورون متصل به ولتاژ تنظیم مجدد آن تنظیم می‌شود. این برای جلوگیری از شلیک نورون‌ها در لحظه بازیابی استخر به دلیل ورودی‌هایی است که هنگام غیرفعال شدن استخر دریافت کرده است. دلیل اضافی برای این تصمیم این است که نورون‌های واقعی هنگام ادغام ورودی‌ها انرژی مصرف می‌کنند، بنابراین اگر انرژی برای مصرف وجود نداشته باشد، قادر به ادغام ورودی‌ها نخواهند بود. این رژیم مصرف انرژی منجر به رفتار هیستریزیس فعالیت اسپیک نورون می‌شود. با سرعتی افزایش می‌یابد و سپس به دلیل محدودیت‌های انرژی غیرفعال می‌شود. پس از بازسازی انرژی کافی، به دلیل پتانسیل تنظیم مجدد غشاء، تاخیری قبل از شروع مجدد اسپیک وجود خواهد داشت.

## ۴-۴) روش‌های ارزیابی

برای مشاهده تأثیر محدودیت‌های انرژی و تأثیر اندازه‌های مختلف استخر انرژی، از چند معیار استفاده شد. اینها دقت آموزش و آزمایش بر روی مجموعه داده‌های ارزیابی شده همراه با جداسازی مخزن و توان لیاپانوف<sup>۱</sup> بود.

**جدایی.** جداسازی یک مخزن، معیاری است از میزان پراکندگی ورودی‌های اعمال شده در فضای مخزن. تعریف توسعه یافته همچنین شامل واریانس درون کلاسی در این متریک است. این متریک به طور ویژه مفید است، زیرا ما از روش معادلات عادی برای حل وزن‌های بین مخزن و لایه خروجی استفاده می‌کنیم، که اگر حالت‌های مخزن به صورت خطی قابل تفکیک باشند بهترین عملکرد را دارد. کیفیت جداسازی به صورت زیر تعریف می‌شود:

$$\text{Separation} = \frac{\text{Sep}_d}{\text{Sep}_v + 1} \quad (18)$$

<sup>۱</sup> Lyapunov

که  $Sep_d$  فاصله بین طبقاتی و  $Sep_v$  واریانس درون کلاسی ورودی‌های انتزاع شده در فضای مخزن است. فاصله بین طبقاتی به صورت زیر تعریف می‌شود:

$$Sep_d = \sum_{i=1}^N \sum_{j=1}^N \frac{\|C_m(O_i) - C_m(O_j)\|_2}{N^2} \quad (19)$$

که  $O_i$  مجموعه‌ای از حالت‌های مخزن برای کلاس ورودی  $i$  از  $N$  کلاس ورودی است.  $C_m$ ، "مرکز جرم" با [۵] به صورت زیر تعریف می‌شود:

$$C_m(O) = \frac{\sum_{O_j \in O} O_j}{|O|} \quad (20)$$

واریانس درون طبقه‌ای کیفیت جداسازی به صورت زیر تعریف می‌شود:

$$Sep_v = \frac{1}{N} * \sum_{i=1}^N \rho_i \quad (21)$$

که  $\rho_i$  به صورت زیر محاسبه می‌شود:

$$\rho_i = \frac{\sum_{O_j \in O_i} \|C_m(O_i) - O_j\|_2}{|O_i|} \quad (22)$$

#### ۴-۵) نتیجه‌گیری

هنگامی که LSM در دو نسخه از مجموعه داده‌های تشخیص تشنج EEG اعمال شد، با حداکثر افزایش مشاهده شده ۴٫۲۵٪ تا ۹۰٫۱۷٪ برای یک دیجیتال، مشاهده شد که استفاده از یک مدل محدودیت‌های انرژی متابولیک در یک ماشین حالت مایع به طور قابل توجهی دقت تست را بهبود می‌بخشد. LSM این افزایش دقت با جداسازی مخزن برای هر دو نسخه مجموعه داده تشخیص تشنج روند رو به رو شد و توضیحی به این پدیده داد. اگرچه این احتمال وجود دارد که بهبود دقت مشابهی با تنظیم دقیق سایر فرآیندها در LSM به دست آید، محدودیت‌های انرژی متغیر ممکن است راه‌حل ساده‌تری برای مثال، پیاده‌سازی LSM در سخت‌افزار باشد که در آن اصلاح اتصال مخزن ممکن است گزینه‌ای نباشد. این بیشتر توسط مشاهداتی که افزایش دقت در LSM دیجیتال با وزن‌های با دقت ثابت هنگام اعمال

محدودیت‌های انرژی مشاهده می‌شود، پشتیبانی می‌شود، در حالی که تعداد اسپک‌ها را کاهش می‌دهد که ممکن است منجر به صرفه‌جویی در انرژی دستگاه شود.



## فصل پنجم

### ماشین‌های حالت مایع مبتنی بر مم‌ریستور

## ۵-۱) سیستم های نورومورفیک<sup>۱</sup>

اخیراً، سیستم های خودمختار سیار در کاربردهایی مانند روباتیک، پهپادها و حسگرها اهمیت پیدا کرده اند. برای برآورده ساختن عملکرد بالا، ضریب فرم کوچک و انرژی کم برای چنین کاربردهایی، یک بستر سخت افزاری اختصاصی مورد نیاز است. به دلیل موازی بودن و همگنی زیاد در یادگیری، سخت افزارهای تخصصی می توانند به عنوان یک شتاب دهنده عمل کنند. سخت افزار نورومورفیک با استفاده از CMOS و ممریستورها<sup>۲</sup> که به عنوان سیستم های حافظه عصبی<sup>۳</sup> شناخته می شوند، چندین مزیت را نسبت به پیاده سازی های سنتی CMOS ارائه می دهند که بهره وری انرژی یک مزیت کلیدی است. این سیستم های حافظه عصبی معمولاً از یک نوار متقاطع حافظه دار برای انجام عملیات سیناپسی و یادگیری آنلاین استفاده می کنند که یک عملیات غالب در شبکه های بزرگ است. قابلیت اطمینان سخت افزار نورومورفیک به طور کلی یک حوزه مورد مطالعه نیست، زیرا انعطاف پذیری یک ویژگی مورد انتظار در این سیستم ها است. با این حال، مشاهده می شود که هسته اجزای به کار رفته در سیستم های عصبی حافظه می توانند بر یادگیری تأثیر بگذارند و مشخص کردن این رفتار می تواند ما را در طراحی سیستم های قوی راهنمایی کند.

این فصل به بررسی استحکام الگوریتم های یادگیری، معروف به محاسبات مخزن (RC)، که دارای سرعت های آموزشی بالایی هستند و می توانند به راحتی بر روی پلتفرم های تعبیه شده مستقر شوند، می پردازد.

RC یک الگوریتم مفید برای مطالعه قابلیت اطمینان و استحکام سیستم های نورومورفیک است، به دلیل مناسب بودن آن برای حل طیف گسترده ای از مسائل. معماری LSM برای انجام تجزیه و تحلیل سطح بالایی از منابع مختلف نويز که بر یک سیستم عصبی مغزی تأثیر می گذارند، انتخاب شد. نويز ایجاد شده توسط ویژگی های غیر ایده آل در دستگاه های ممریستور به صورت زیر ظاهر می شود. نويز حرارتی، نويز تصادفی تلگراف، و مکانیسم های فرسودگی مورد توجه خاصی قرار داشتند. انگیزه این کار چند سوال است.

<sup>1</sup> Neuromemristive

<sup>2</sup> Memristor

<sup>3</sup> Neuromemristive

وقتی یک نورون یا سیناپس فردی در این سیستم‌ها معیوب باشد چه اتفاقی می‌افتد؟ وقتی خوشه‌ای از نورون‌ها معیوب هستند چه اتفاقی می‌افتد؟ آیا شبکه از تخریب پشتیبانی می‌کند؟

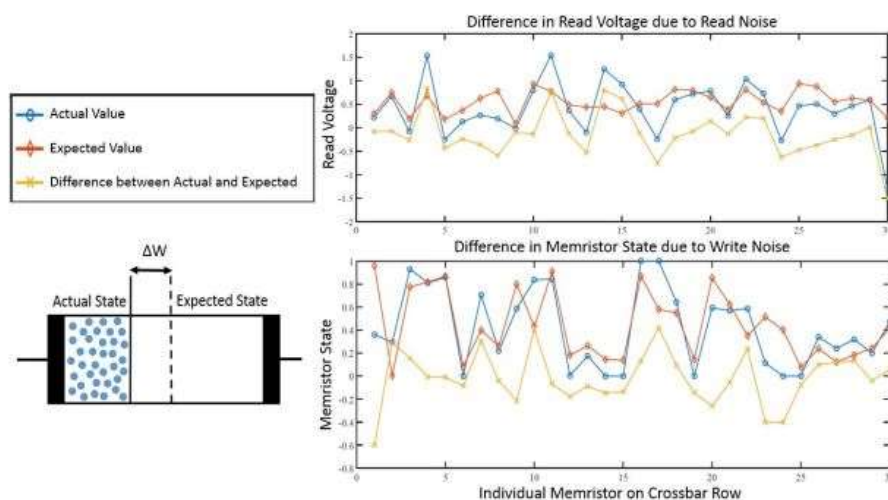
## ۵-۲) نویز و تغییرپذیری

نویز ممکن است به دلیل غیرقابل اطمینان بودن دستگاه‌های memristive در اجرای نورومورفیک یک LSM رخ دهد. به طور کلی، یک دستگاه مم‌ریستور دو ترمینالی را می‌توان با اعمال اختلاف پتانسیل کافی در سرتاسر پایانه‌های آن برنامه ریزی کرد، جایی که تغییر حالت دستگاه به بزرگی، مدت زمان و قطبیت اختلاف پتانسیل بستگی دارد. بسته به قطبیت ولتاژ اعمال شده، وضعیت دستگاه بین حالت مقاومت بالا (HRS) یا حالت مقاومت کم (LRS) متفاوت است. این تحقیق اثرات دستگاه‌های مم‌ریستور مبتنی بر ردوکس<sup>۱</sup> غیر استوکیومتری را همانطور که به صورت تجربی در سطح بالا، رفتار غیر ایده آل در دستگاه‌های حافظه دار به صورت نویز خواندن از طریق سیناپس یا نویز نوشتن هنگام به روزرسانی قدرت سیناپسی ظاهر می‌شود.

سه منبع نویز خواندن وجود دارد: نویز تصادفی تلگراف (RTN)، نویز حرارتی و نویز  $1/f$ . منبع غالب ناپایداری از RTN ناشی می‌شود، به دلیل فرآیندهای به دام انداختن تک الکترون، که باعث می‌شود جریان از طریق دستگاه بین دو حالت نوسان کند، که می‌تواند با توزیع گاوسی مدل شود. نویز حرارتی با در نظر گرفتن مم‌ریستور به عنوان یک مقاومت ساده در نظر گرفته می‌شود که می‌توان آن را با  $k$  ثابت بولتزمن،  $T$  دما،  $M(t)$  مم‌ریستانس آنی و  $\Delta f$  پهنای باند در نظر گرفت. یک توزیع گاوسی با میانگین  $\sigma$  و متغیر  $\sigma$  از ۱٪ تا ۵۰٪ در جریان سیناپسی در طول خواندن برای مدل سازی اثر ترکیبی RTN و نویز حرارتی در LSM ما استفاده می‌شود که در زیر نشان داده شده است.

$$V_N^2 = 4kTM(t)\Delta f \quad (23)$$

<sup>۱</sup> Redox




شکل ۱۳-۱ نویز ممپرستور: (سمت چپ) تفاوت بین وضعیت مورد انتظار و واقعی یک دستگاه ممپرستیو (بالا سمت راست) تاثیر نویز خواندن (پایین سمت راست) تاثیر نویز نوشتن

نویز نوشتن به دلیل تغییرات دستگاه است که در هنگام آموزش شبکه LSM به دو اثر تبدیل می‌شود. اولی انحراف در حالت حداکثر مقاومت بالا (HRS) و حالت مقاومت کم (LRS) دستگاه است که از تغییرات فرآیندی مانند زبری لبه خط، نوسان ضخامت ممپرستور و دوپینگ گسسته تصادفی ناشی می‌شود. تغییرات  $3\sigma$  حالت های HRS و LRS تقریباً ۷ درصد مقدار مورد انتظار است. ممپرستورهای HRS و LRS تأثیر مستقیمی بر آموزش شبکه خواهند داشت زیرا ممکن است فضای وزنی را برای یادگیری LSM تغییر دهند، جایی که وضعیت واقعی حالت مورد انتظار نیست. دومین محدودیت طراحی که باید در نظر گرفته شود، تفاوت در زمان های نوشتن مورد نیاز برای به روز رسانی یک وضعیت معین است. برای یک دستگاه، این بدان معناست که یک پالس به روز رسانی ثابت منجر به تغییر حالت برابر در هر پالس نمی‌شود. در سراسر دستگاه‌ها، یک پالس به‌روزرسانی ثابت منجر به تغییرات حالت متفاوتی می‌شود، حتی اگر دستگاه‌ها شرایط اولیه یکسانی داشته باشند. تجلی این منابع نویز در سطح دستگاه در شکل بالا نشان داده شده است که در آن تفاوت بین وضعیت واقعی دستگاه و حالت مورد انتظار نشان داده شده است. انحراف استاندارد در زمان نوشتن برای دستگاه‌های مختلف تقریباً ۴٪ است.

### ۵-۳) مدل سیستم مقاوم در برابر نویز

برای مطالعه قابلیت اطمینان طراحی، یک مدل رفتاری از شبکه LSM نشان داده شده در شکل زیر شبیه سازی شده و در معرض منابع مجزای نویز قرار می گیرد. اندازه شبکه ۲۰۰ نورون، با ۱۶۰ محرک و ۴۰ بازدارنده استفاده شده است. سه ۲۴۱ مجموعه داده مختلف، با تعداد کلاس‌ها، ویژگی‌ها و اندازه‌های متفاوت برای مطالعه تأثیرات بر یادگیری استفاده می‌شوند. یک مجموعه داده فرکانس مصنوعی، با ۵ کلاس و ۵ ویژگی به عنوان یک بستر آزمایشی پایه استفاده می‌شود.



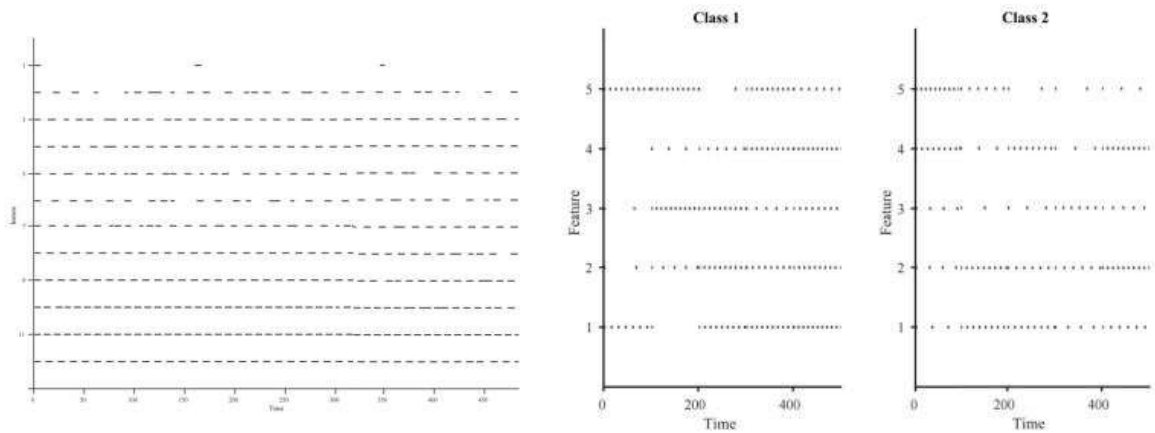
شکل ۱۴-۲ طراحی سیگنال مختلط (LSM سمت چپ) میله متقاطع و مدارهای جانبی آن (راست) جریان داده بین واحدهای مختلف مورد نیاز برای تحقق کامل LSM

این امر از درک اثرات منابع مستقل نویز در نوار متقاطع ممبرستور LSM (نشان داده شده در شکل ۴) پشتیبانی می‌کند. تعداد ویژگی‌ها در داده‌های فرکانس مصنوعی با جaro کردن اندازه‌های ویژگی مختلف و مشاهده استحکام LSM در اثر نویز ترکیبی انتخاب می‌شوند. اثر ترکیب نویز نیز بر روی مجموعه داده پیکره گفتار TIMIT (شکل ۵) و مجموعه ارقام عربی گفتاری (شکل ۶) مورد مطالعه قرار گرفته است. مجموعه گفتار TIMIT مجموعه ای از ۶۳۰ سخنرانی با گویش های مختلف است که جملات مختلفی را بیان می‌کنند. داده ها با جمله، کلمه و واج برچسب گذاری می‌شوند. مجموعه داده های گفتاری عربی، ضرایب ضایعات مغزی فرکانس (mfcc) سخنرانان مرد و زن است که ارقام ۰ تا ۹ را به عربی می‌گویند.

برای داده های TIMIT ما ۴ واج را طبقه بندی کردیم. «e»، «eh»، «er» و «u» و وظیفه طبقه بندی تمام ۱۰ رقم بود. به منظور تبدیل ضرایب ضایعات مغزی فرکانس به قطارهای سنبله به صورت زیر عمل می کنیم


$$\text{Rate}_i(t) = \frac{mfcc_i(t)}{\Omega_i - w_i} * \text{MaxRate} \quad (24)$$

که  $\Omega_i$  بزرگترین mfcc ورودی  $i$  و  $w_i$  کوچکترین است. در شبکه ما حداکثر نرخ شلیک (MaxRate) نورون های ورودی را ۱۰۰ هرتز تنظیم می کنیم. این معادله یک نرخ اسپیک برای هر mfcc می دهد.



شکل ۱۷-۴ نمونه داده های ورودی از مجموعه داده TIMIT.

شکل ۱۶-۳ دو کلاس نمونه از مجموعه داده فرکانس مصنوعی مورد استفاده برای تجزیه و تحلیل پایه.



شکل ۱۵-۵ نمونه داده های ورودی از مجموعه داده های رقم گفتاری عربی.

یک اثر طبیعی تر در هر دستگاه حافظه غیر فرار نوظهور، تغییر زمان نوشتن است. هنگامی که با انحراف در حالت مقاومت بالا و مقاومت کم ترکیب شود، تأثیر بر یادگیری می تواند به طور بالقوه قابل توجه باشد. حالت های مقاومت حداکثر و حداقل با رابطه زیر تعیین می شود.

$$\frac{M_{HRS}}{LRS} = M_{max/min} + \Delta M \quad (25)$$

که  $M$  ممیستانس دستگاه و  $\Delta M \sim N(0, \sigma^2)$  است.

در نهایت، برای درک استحکام LSM در شرایط خارجی، یک لایه مایع که خروجی اشتباهی در هر مرحله زمانی تولید می کند در نظر گرفته می شود. این مشابه با درجه بالایی از نویز سیناپسی است که می تواند بر تصمیم نوروها تأثیر بگذارد. در این سناریو، تعداد ثابتی از نوروها به طور تصادفی از یک توزیع یکنواخت انتخاب می شوند تا خروجی اشتباه داشته باشند. تعداد نوروهای از کار افتاده از ۱٪ به ۳۰٪ (از کل نوروهای مایع) جاروب می شود.

بنابراین می توان نتیجه گرفت LSM نسبت به نویزها و تغییرات فرآیندی که در سیستم های عصبی-مهریستو رخ می دهد قوی است. به علاوه می توان نتیجه گرفت که الگوریتم LSM به دلیل کاهش پیچیدگی و استحکام آن نسبت به ویژگی های دستگاه حافظه دار غیر ایده آل، برای پیاده سازی به عنوان یک شتاب دهنده neuromemristive مناسب است.

## فصل ششم

### تولید مخزن هوشمند در ماشین های حالت مایع



## ۶-۱) انگیزه و طرح مسئله

شبکه‌های عصبی بازگشتی (SRNN) یک مدل محاسباتی محبوب هستند. این تا حدی به دلیل ظهور سیستم‌های نورومورفیک اسپکینگ تجاری مانند TrueNorth IBM و Loihi اینتل است. به دلیل توانایی‌های نظری خود، آنها قادر به مقابله با وظایف پیچیده مانند پردازش داده‌های مکانی و زمانی هستند. یک سوال کلیدی مرتبط با SRNN ها، آموزش، هم برای SRNN های عمومی و هم برای آنهایی است که با قصد استقرار در سیستم‌های عصبی واقعی ساخته شده‌اند. به طور خاص، تعیین توپولوژی شبکه (تعداد نوروها و سیناپس‌ها و اتصال آنها) و همچنین پارامترهای شبکه (وزن‌ها، آستانه‌ها و غیره) کار ساده‌ای نیست. برای دستیابی به قدرت محاسباتی کامل SRNN ها و در نتیجه سیستم‌های نورومورفیک، ضروری است که الگوریتم‌های موثری برای ساخت SRNN های متناسب با وظایف واقعی ایجاد کنیم.

ما دو تکنیک بهینه‌سازی را برای ایجاد تصادفی مخازن در یک ماشین حالت مایع پیاده‌سازی محاسبات مخزن بررسی می‌کنیم. روش اول جستجوی شبکه‌ای بر روی دو ابرپارامتر – نوروهای پنهان و چگالی سیناپسی است که در آن مخازن تصادفی در هر نمونه از جستجوی شبکه ایجاد می‌شود. تکنیک دوم از یک الگوریتم ژنتیکی به نام بهینه‌سازی تکاملی سیستم‌های نورومورفیک (EONS) استفاده می‌کند، که در آن جمعیت‌های تصادفی کوچک‌تری از مخازن ایجاد می‌شوند و سپس برای بهینه‌سازی مخازن تکامل می‌یابند. ما دو رویکرد را در مورد یک مشکل طبقه‌بندی که توسط یک سیستم نورومورفیک اسپکینگ به نام DANNA2 اجرا شده است مقایسه می‌کنیم. ما همچنین تأثیر معیارهای استاندارد برای مخازن را بر روی هر یک از مخازن تولید شده توسط هر دو تکنیک بررسی می‌کنیم.


## ۶-۲) مدل شبکه و آموزش آن

یک ماشین حالت مایع (LSM)، که در شکل ۱ نشان داده شده است، یک مدل محاسباتی است که رفتار متغیر با زمان شبکه‌های عصبی پراکنده مکرر را به عنوان فیلتری برای اطلاعات ترکیب می‌کند. مدل LSM شامل سه بخش است. یک لایه ورودی، مایع و یک لایه بازخوانی. برای اینکه یک شبکه عصبی اسپکینگ بتواند به عنوان مایع یا مخزن موفق عمل کند، باید دو ویژگی مهم داشته باشد: قابلیت تفکیک

ورودی و حافظه محو. تفکیک پذیری ورودی به سادگی به این معنی است که مایع داده ها را به گونه ای فیلتر می کند که در صورت ورودی های مختلف، به حالت های مختلف می رسد. بدون این ویژگی، مکانیزم بازخوانی قادر به تمایز بین ورودی های مختلف نخواهد بود. به عنوان مثال، معیارهایی مانند فاصله اقلیدسی را می توان برای ردیابی نرخ تفکیک پذیری در بین بردارهای خروجی استفاده کرد. محو شدن حافظه الزامی است که یک ورودی واحد به صورت بازگشتی تا بی نهایت منتشر نشود. چندین معیار از پایداری مخزن مورد بررسی قرار گرفته است، مانند شعاع طیفی و ژاکوبین ماتریس وزن. این ویژگی ها معیارهای عددی پایداری مخزن را با توجه به حافظه محو می کنند و در مطالعات الگوریتم های ژنتیک برای تولید مخزن استفاده شده اند.

اگر شبکه ای دارای تفکیک پذیری ورودی و حافظه محو شده باشد، می توان ثابت کرد که یک تقریب کننده تابع جهانی از طریق قضیه استون-وایرشراس است. در تئوری، اگر یک شبکه عصبی اسپک دارای این دو ویژگی باشد، می تواند به عنوان مایع برای یک LSM عمل کند. بنابراین، تنها مرحله آموزشی برای مؤلفه شبکه عصبی spiking این است که اطمینان حاصل شود که شبکه به اندازه کافی پیچیده است که هر دو ویژگی مورد نیاز مایع را داشته باشد. این می تواند مایعات تولید شده به طور تصادفی را به مقدار کافی تولید کند. با این حال، احتمال اینکه یک شبکه به طور تصادفی تولید شده به خوبی برای یک مسئله مشخص کار کند به اطلاعات قبلی مانند اندازه نسبی مایع تولید شده به طور تصادفی بستگی دارد. همچنین بستگی به مسئله ای دارد که باید حل شود. فرایامترهایی مانند تعداد نورون های پنهان، چگالی سیناپسی، توپولوژی واقعی (اتصالات)، مقادیر ناشی و سایر پارامترهای شبکه قابل تنظیم می توانند بر موفقیت مخزن تأثیر بگذارند. از این نظر، محققان اغلب مجبورند بسیاری از شبکه ها را قبل از رسیدن به یک مخزن موفق یا بهینه تولید و ارزیابی کنند، حتی زمانی که مجموعه ای معتبر از فرایامترها انتخاب شده اند. به علاوه، الگوریتم های ژنتیک می توانند به تولید توپولوژی های موفق بدون نیاز به شهود در مورد این ویژگی ها از قبل کمک کنند.

پس از تولید مایع بالقوه، تحریک می شود تا حالت هایی برای پس پردازش ایجاد کند. لایه بازخوانی برای طبقه بندی اطلاعات از بردارهای حالت مخزن استخراج شده آموزش داده شده است.



شکل ۱۸-۱ نمودار محاسبات مخزن. ورودی به مخزن (در این مورد مایع) منتقل می‌شود، سپس پس از مدت زمان از پیش تعیین شده، از مخزن نمونه برداری می‌شود و نمونه به عنوان بردار ویژگی به لایه بازخوانی منتقل می‌شود.

به طور خاص، لایه بازخوانی معمولاً با رگرسیون خطی آموزش داده می‌شود، اگرچه تعریف ماشین حالت مایع به اندازه‌ای کلی است که انواع لایه‌های بازخوانی مانند ماشین‌های بردار پشته‌ای، پرسپترون‌ها یا رگرسیون لجستیک چند متغیره (softmax) را مجاز می‌سازد.

در اینجا، ما از یک رگرسیون لجستیک چند جمله‌ای برای لایه بازخوانی استفاده می‌کنیم. ماتریس وزن با نزول گرادیان و الگوریتم پس انتشار آموزش داده می‌شود. ورودی به مایع وارد می‌شود، که حالت آن را در طول فرآیند رویدادهای spiking تغییر می‌دهد. این حالت تغییر یافته (خروجی‌های مایع) است که برای پردازش توسط لایه بازخوانی گرفته می‌شود. پس از تعداد چرخه‌های شبیه‌سازی از پیش تعیین شده، حالت مایع گرفته می‌شود و به طبقه‌بندی کننده softmax منتقل می‌شود. نمایش حالت مایع درون یک بردار قرار دارد. بردار حالت  $Z$  که در این کار استفاده می‌کنیم شامل تعداد اسپک‌هایی است که یک خروجی در طول شبیه‌سازی تولید می‌کند و حاوی عناصری برابر با تعداد خروجی‌های شبکه است. یک حالت مربوط به یک ورودی خاص ممکن است دوباره استفاده شود. لازم نیست برای هر مرحله آموزشی دوباره شبیه‌سازی شود. از نظر ریاضی، نمایش به شرح زیر است:

$$Z_i = \sum_j^N \text{Output}_{i,j} \quad (26)$$

$N$  معادل تعداد گام‌های زمانی شبیه‌سازی شده است. اگر نورون خروجی  $i$  در مرحله زمانی  $j$  شلیک نشود، بردار  $\text{Output}_{i,j}$  صفر بوده و در صورتی که نورون خروجی شلیک شود، یک است.  $Z_i$  وضعیت خروجی  $i$  را نشان می‌دهد. بردار حالت پس از شبیه‌سازی محاسبه شده و به لایه بازخوانی منتقل

می‌شود. به جای یک عکس فوری از کل وضعیت مایع در یک زمان خاص، بردار حالت رفتار دینامیکی شبکه را از طریق اسپیک‌های خروجی ردیابی می‌کند. توجه داشته باشید که این فقط یک نمایش حالت ممکن است که برای سهولت محاسبات استفاده می‌شود. سایر احتمالات وجود دارد و می‌تواند عملکرد طبقه بندی را از طریق استفاده از اطلاعات گسترده تر از قطارهای سنبله، مانند فیلتر کردن نمایی پایین گذر سیگنال های سنبله تولید شده، بهبود بخشد.

نمایشی که در بالا توضیح داده شد برای تعیین خروجی نهایی از لایه بازخوانی عبور داده می‌شود. در طول مرحله آموزش، لایه بازخوانی سپس گرادینان خطای تابع هزینه خطای softmax و مربعی را محاسبه می‌کند. در نهایت، پس انتشار برای به روز رسانی وزن‌ها استفاده می‌شود.

### ۳-۶ بهینه سازی تکاملی سیستم های نورومورفیک

برای الگوریتم ژنتیک خود، از بهینه سازی تکاملی سیستم‌های نورومورفیک (EONS) استفاده می‌کنیم. چیزی که EONS را جالب می‌کند این است که نه تنها هایپرپارامترهای عددی SRNN، بلکه ساختار آنها را نیز بهینه می‌کند. شبکه‌ها در جمعیت‌های EONS به صورت نمودارهایی نشان داده می‌شوند که در آن گره‌ها و لبه‌ها دارای پارامترهای بهینه سازی هستند. عملیات متقاطع و جهش از این نمایش مبتنی بر نمودار استفاده می‌کند.

هر برنامه کاربردی باید یک تابع تناسب را اجرا کند که یک شبکه را به عنوان ورودی می‌گیرد و یک امتیاز عددی واحد را برمی گرداند، که در آن نمرات تناسب بالاتر مربوط به شبکه‌هایی با عملکرد بهتر است. چارچوب EONS هم توپولوژی شبکه (تعداد نوروها و سیناپس‌ها و الگوی اتصال) و هم پارامترهای شبکه (وزن‌ها، آستانه‌ها و غیره) را تعیین می‌کند که متفاوت از لایه بازخوانی در محاسبات مخزن است.

ما دو روش را برای آموزش ماشین‌های حالت مایع بررسی می‌کنیم: جستجوی شبکه و EONS. برای استفاده از EONS، باید مقدار تناسب را برای هر شبکه در جمعیت ارائه کنیم. ارزش تناسب اندام در چند مرحله محاسبه می‌شود. ابتدا، شبکه با اعمال اسپیک‌ها در طول زمان تحریک می‌شود. پس از گذراندن تعداد از پیش تعیین شده مراحل زمانی، بردارهای حالت در قالبی که در بخش قبل توضیح داده

شد جمع آوری می شوند. سپس لایه بازخوانی آموزش داده می شود. تناسب به دست آمده توسط لایه بازخوانی به عنوان مقدار تناسب برگردانده می شود.

## ۴-۶) آزمایشات

در اینجا ما بر روی مجموعه داده های Ionosphere به عنوان یک مطالعه موردی تمرکز می کنیم، زیرا هدف ما نشان دادن سودمندی EONS در مقایسه با جستجوی شبکه است. ابتدا مجموعه داده را شرح می دهیم. سپس، به آزمایشی که انجام دادیم می پردازیم. در نهایت نتایج به دست آمده با هر یک از روش های جداگانه را بررسی خواهیم کرد.

**Ionosphere:** مجموعه داده Ionosphere مجموعه ای از اطلاعات است که توسط یک آرایه فازی از ۱۶ آنتن فرکانس بالا تولید می شود. آنتن ها الگوی چند پالس را ارسال می کنند که الکترون های آزاد را در یونو سفر هدف قرار می دهد. یک گیرنده در بین پالس ها فعال می شود. نتیجه ۱۷ عدد پالس است که هر کدام از ۲ مشخصه پیچیده تشکیل شده است که سیگنال الکترومغناطیسی را نشان می دهد و در مجموع ۳۴ ویژگی با ارزش پیوسته را به وجود می آورد. هر یک از ۳۴ نمونه به محدوده ۱۰ پالس در یک نورو و ورودی جداگانه، با فاصله زمانی ۱ مرحله ای بین پالس ها تبدیل می شود. بنابراین، ۳۴ ورودی، که هر کدام تعدادی پالس متناسب با مقدار ورودی را می تابد. تغییر فاز بازده برای تعیین سرعت هدف اندازه گیری می شود. به طور خاص، یک تابع همبستگی خودکار بر روی سیگنال برگشتی محاسبه می شود که می تواند برای تعیین سرعت داپلر هدف استفاده شود. اگر هدفی با سرعت ثابت حرکت کند، تابع همبستگی خودکار یک تغییر فاز متناسب با عدد پالس را نشان می دهد. در صورت شناسایی ساختار، یک نمونه بازده راداری "خوب" تعیین می شود (و تغییر فاز متناسب است)، و در غیر این صورت "بد" تعیین می شود. نتایج محاسبات مخزن از مخازن تولید شده به طور تصادفی قبلاً ۹۲ درصد گزارش شده بود، اما دقت ۹۶ درصد نمونه ای از الگوریتم های یادگیری ماشین سنتی است که بالای ۹۸ درصد است.

**طرح آزمایش:** برای آزمایش ما ۶۰۰۰۰ شبکه را با استفاده از جستجوی شبکه و EONS ارزیابی کردیم که در مجموع به ۱۲۰۰۰۰ ارزیابی شبکه منجر شد. تعداد آزمایش ها یکسان نگه داشته شد تا نتایج هر روش با همان تعداد شبیه سازی شبکه نشان داده شود. ۳۴ ورودی به مخزن، ۲۰ خروجی


از مخزن به بازخوانی و یک لایه softmax با دو خروجی برای بازخوانی وجود دارد. بازخوانی در هر شبکه جداگانه برای ۱۰۰۰ دوره با نرخ یادگیری ۰,۰۰۱ (به صورت تجربی تعیین شده) آموزش داده شد. وزن های سیناپسی DANNA2 از ۲۵۶- تا ۲۵۵، و تاخیرها از ۰ تا ۲۵۵ متغیر است. مقادیر به طور یکنواخت در این محدوده برای تولید توزیع می شوند.

ما دقت آموزش و آزمایش هر یک از ۱۲۰۰۰۰ شبکه ارزیابی شده و همچنین معیارهای مربوط به محاسبات مخزن را که در بخش های قبلی مورد بحث قرار گرفت، ثبت کردیم. به طور خاص، ما به شعاع طیفی شبکه ها نگاه می کنیم که مربوط به ویژگی حافظه محو می شود. ما همچنین ضریب silhouette را که یک معیار رایج در آمارهای مختلف از ۱,۰- تا ۱,۰ است، ثبت کردیم. ضریب silhouette نشان دهنده اعتبار خوشه های تولید شده توسط روش های خوشه بندی است. مقدار ضریب ۱,۰- به این معنی است که همه نقاط به اشتباه خوشه بندی شده اند و مقدار ۱,۰ نشان دهنده خوشه های کاملاً معتبر است. در زمینه محاسبات مخزن، یک مقدار واحد است که می تواند به عنوان نمایشی از توانایی یک مایع برای جدا سازی اطلاعات در نظر گرفته شود و از بردارهای حالت تولید شده با نمونه برداری از یک مایع پس از تحریک محاسبه می شود.

## ۵-۶) نتایج

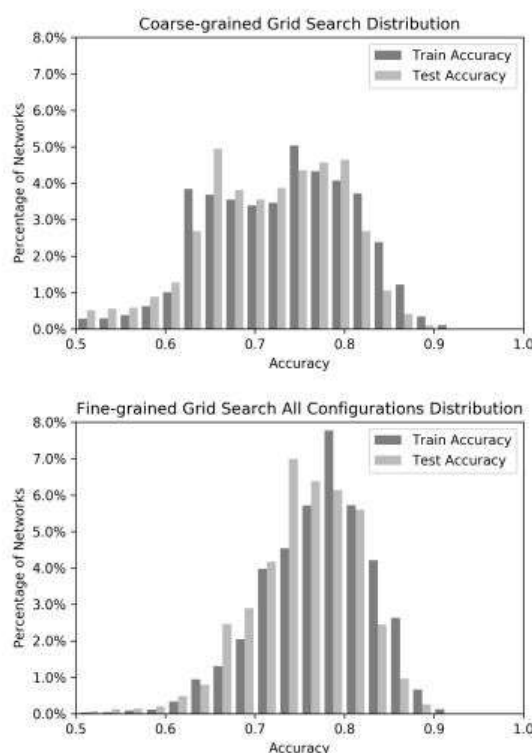
دانستن اینکه از کجا باید با فرآپارامترها برای تولید ماشین حالت مایع شروع کرد، ممکن است نامشخص باشد. دستورالعمل ها و توصیه هایی برای محاسبات مخزن وجود دارد، اما اغلب محققان مجبورند شبکه های تصادفی زیادی را برای یافتن یک راه حل رضایت بخش ایجاد کنند. برای نشان دادن این، ما یک جستجوی شبکه ای انجام دادیم که تعداد نورون های پنهان و چگالی سیناپسی (نسبت به تعداد نورون های پنهان) را تغییر می دهد. تعداد نورون های پنهان از ۱۰ تا ۱۰۰ با افزایش ۱۰ درصدی و چگالی سیناپسی از ۵٪ تا ۵۰٪ با افزایش های ۵٪ متغیر بود. برای هر یک از این تنظیمات، ۱۰۰ شبکه تصادفی تولید شد. پس از جستجوی شبکه درشت دانه، پنج بهترین تنظیمات فرآپارامتر برای تعداد نورون های پنهان و چگالی سیناپسی انتخاب شدند و یک جستجوی شبکه ای ریزدانه انجام شد که در آن جستجو را دقیق تنظیم کردیم تا در بین بهترین پیکربندی ها با افزایش متفاوت باشد. از ۱ نورون و ۱٪

چگالی سیناپسی (همچنین با ۱۰۰ شبکه در هر پیکربندی). در مجموع، جستجوی شبکه در شت دانه ۱۰۰۰۰ تست و هر جستجوی شبکه ریزدانه ۱۰۰۰۰ تست بود که در مجموع ۶۰۰۰۰ تست را شامل شد. نتایج مربوطه در نقشه های حرارتی در شکل زیر نشان داده شده است. دو نقشه حرارتی بالا مربوط به آموزش جستجوی شبکه در شت و دقت تست هستند. واضح است که پیکربندی های خاصی بهتر از سایرین عمل می کنند، بالاترین چگالی سیناپسی که منجر به سطوح بسیار پایین تری از دقت می شود. این نتیجه از آشفستگی بیش از حد فعالیت شبکه برای انتقال اطلاعات است. موفقیت به ترکیب نوروها و چگالی سیناپسی بستگی دارد تا به یکی از این دو پارامتر. به عبارت دیگر، این یک توزیع احتمال مشترک را تشکیل می دهد. برای نشان دادن بیشتر اهمیت پیکربندی های پارامتر، نتایج جستجوی دقیق را در بهترین نقطه دقت تمرین نمایش می دهیم: ۶۰ نورو با تمرکز بر تراکم سیناپسی ۰.۱۵. نقشه های حرارتی پایین مربوط به این جستجو هستند، و نشان می دهند که دقت بالایی در سراسر طیف فرآپارامترها زمانی که یک پیکربندی دانه درشت مناسب پیدا می شود، به دست می آید.



شکل ۱۹-۲ نقشه های حرارتی بالا از یک جستجوی شبکه دو سطحی در مخازن به طور تصادفی ایجاد شده بر روی مجموعه داده های یونسفر ایجاد شده اند. هر بلوک در نقشه حرارتی نشان دهنده بهترین دقت از جمعیت ۱۰۰ نفری است. تعداد نوروهای پنهان و چگالی سیناپسی به ترتیب در محورهای  $y$  و  $x$  متفاوت است.

با این حال، مهم است که توجه داشته باشید که این نقشه‌های حرارتی بهترین دقت به دست آمده از ۱۰۰ شبکه را برای هر پیکربندی نشان می‌دهد. حتی پس از یافتن انتخاب مناسبی از فرآپارامترها، توزیع موفقیت مخزن می‌تواند به شدت متفاوت باشد. این در شکل زیر نشان داده شده است و به عنوان نمونه ای از نیاز به ارزیابی چندین مخزن قبل از یافتن یک مخزن موفق عمل می‌کند. یک جستجوی جامع برای دانستن توزیع واقعی مخازن موفق مورد نیاز است.



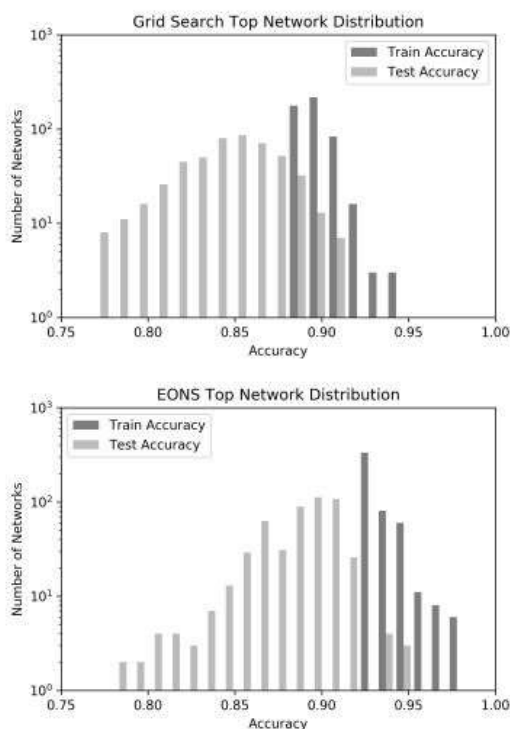
شکل ۲۰-۳ هیستوگرام‌های نشان داده شده در بالا نشان دهنده توزیع دقت در بین پیکربندی‌های مورد استفاده در جستجوی شبکه است. در یک جستجوی دقیق در میان یک انتخاب خوب از فرآپارامترها، ممکن است ارزیابی‌های مایع زیادی مورد نیاز باشد. توزیع دقت به طور متوسط در رویکرد ریزدانه بالاتر است، اما مخازن با بالاترین عملکرد هنوز هم بخش کوچکی از توزیع کلی هستند.

**نتایج EONS روی LSM:** ما جمعیت هر اجرا EONS را ۵۰ شبکه تنظیم کردیم. ۱۰۰ اجرا را انجام دادیم که هر کدام ۱۲ دوره به طول انجامید و هر کدام با پیکربندی متفاوتی از جستجوی شبکه دانه درشت انجام شده برای تولید تصادفی مطابقت داشت. به عبارت دیگر، یک جمعیت اجرا شده EONS به طور تصادفی با ۱۰ نوروں پنهان و ۵ درصد تراکم اولیه، دیگری ۱۰ نوروں پنهان و تراکم ۱۰



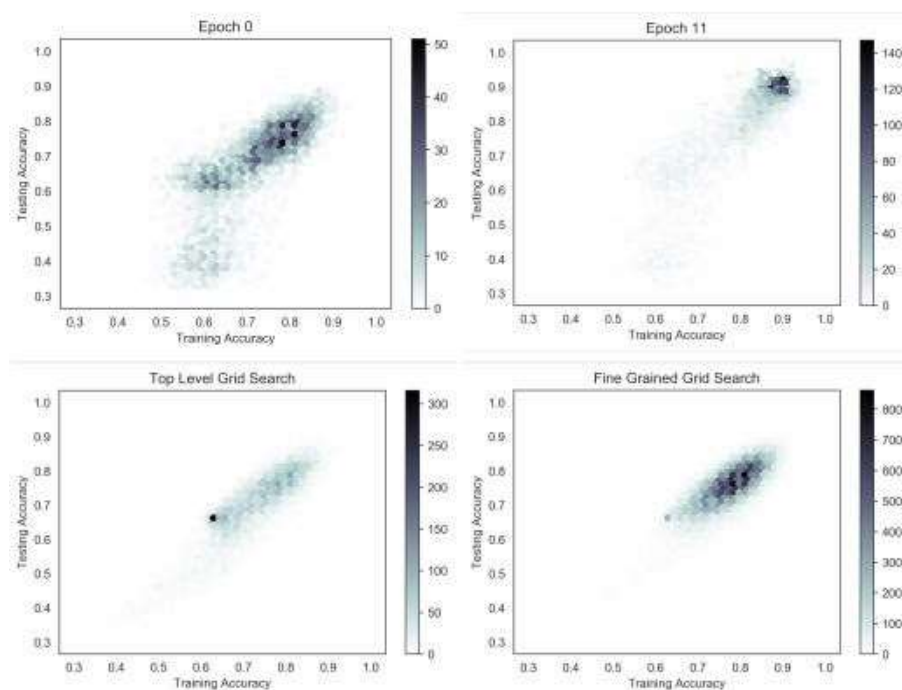
درصد بود. به این ترتیب، برای هر پیکربندی شبکه، یک پیکربندی منطبق برای اجرای EONS وجود داشت.

به منظور مقایسه مستقیم موفقیت بین جستجوی شبکه و اجرای EONS، ما تمام ۶۰۰۰۰ تست را برای هر روش با دقت آموزش مرتب کردیم. سپس ۵۰۰ مایع برتر برای هر روش (بر اساس دقت تمرین) گرفته شد و توزیع دقت رسم شد. شکل زیر نشان می‌دهد که اگرچه هر دو روش قادر به رسیدن به سطوح مورد انتظار از دقت هستند، جستجوی ساخت یافته انجام شده توسط EONS توزیع را به سمت شبکه‌های با عملکرد بالاتر منحرف می‌کند. علاوه بر این، با نگاهی با شکل ۶، می‌توانیم ببینیم که EONS بدون توجه به پیکربندی اولیه جمعیت اولیه، به دقت مورد انتظار همگرا می‌شود. به عبارت دیگر، حتی اگر هر اجرای EONS با تعداد متفاوتی از نوروهای پنهان و ترکیبی از چگالی سیناپسی آغاز شد، همه آنها همگرا می‌شوند. این با تر ما مطابقت دارد، که این است که صرفاً اجازه دادن به جستجوی ساختار یافته



شکل ۲۱-۴ ۵۰۰ شبکه برتر از هر یک از روش‌ها، نمودارها نشان می‌دهد که نتایج EONS به سمت عملکرد بالاتر منحرف شده است. تناسب جزئی بیش از حد را می‌توان از طریق تغییر دستی پارامترها برطرف کرد

هوشمندانه از EONS برای تولید مخازن، بدون توجه به شرایط شروع، به ابرپارامترهای موفق می‌رسد. همانطور که نشان داده شد، این نتیجه‌گیری برای تولید تصادفی صادق نیست.



شکل ۲۲-۵ دو شکل بالا نمودارهای هگزجین آزمایشات EONS انجام شده است. طرح بالا سمت چپ دوره ۰ است، و نمودار بالا سمت راست دوره ۱۱ است. هر طرح شامل تمام ۵۰ شبکه از هر ۱۰۰ اجرا برای مجموع  $k=5$  است. هر شش ضلعی یک سطل را نشان می‌دهد و تمام نمونه‌هایی که در آن ناحیه قرار می‌گیرند در آن سطل ادغام می‌شوند. گرادیان رنگ تعداد نمونه‌های موجود در یک سطل را نشان می‌دهد. EONS بدون توجه به پیکربندی شروع به دقت مورد انتظار همگرا می‌شود، که نتیجه ذاتاً متفاوت از دو نمودار در پایین است. سمت چپ جستجوی شبکه درشت دانه و سمت راست هر ۵ جستجوی شبکه ریز دانه است.

در نتیجه، بهینه‌سازی EONS شبکه‌های بهتری را در کل کشف می‌کند و همچنین با اطمینان بیشتری همگرا شود.

## منابع و مراجع

- [1] J. J. M. Reynolds, J. S. Plank and C. D. Schuman, "Intelligent Reservoir Generation for Liquid State Machines using Evolutionary Optimization," 2019 International Joint Conference on Neural Networks (IJCNN), 2019, pp. 1-8, doi: 10.1109/IJCNN.2019.8852472.
- [2] N. Soures, L. Hays and D. Kudithipudi, "Robustness of a memristor based liquid state machine," 2017 International Joint Conference on Neural Networks (IJCNN), 2017, pp. 2414-2420, doi: 10.1109/IJCNN.2017.7966149.
- [3] Fountain, Andrew & Merkel, Cory. (2020). Energy Constraints Improve Liquid State Machine Performance. <https://arxiv.org/abs/2006.04716>
- [4] Dipayan Das, Saumik Bhattacharya, Umapada Pal, Sukalpa Chanda, PLSM: A Parallelized Liquid State Machine for Unintentional Action Detection. <https://arxiv.org/abs/2105.09909>
- [5] Oladipupo, Gideon. (2019). Research on the Concept of Liquid State Machine. <https://arxiv.org/abs/1910.03354>



**Amirkabir University of Technology  
(Tehran Polytechnic)**

**Department of Computer Engineering**

**Artificial Neural Network Term Paper**

**Improved liquid state machine**

**By  
Alireza Khayyatian**

**Supervisor  
Dr. Safabakhsh**

**Jan & 2022**